

CURSO BÁSICO DE PYTHON

Guía

1. Bases de la programación

Para trabajar con cualquier lenguaje de programación, primero debemos entender cuál es el soporte físico en el que se programa, es decir, la computadora u ordenador. Una computadora es una máquina que ejecuta unos comandos y procesa datos de entrada, que serán enviados a los dispositivos de salida. Las computadoras actuales son máquinas electrónicas, digitales y programables, es decir que están formadas por circuitos electrónicos (circuitos eléctricos formados por componentes de control del flujo de electrones, como diodos y transistores y componentes pasivos, como conexiones, resistencias, etc.), que trabajan en base binaria (en lugar de nuestro sistema en base 10) y que puede realizar tareas diferentes en función de las instrucciones que le demos.

Como en toda la electrónica digital, la base de la programación se encuentra en el sistema binario, que representa el paso / no paso de la corriente eléctrica a través de los componentes electrónicos. En la computación se conoce como **bit** a la mínima unidad de información, que puede tener 2 valores, 0 o 1, y **byte** a un conjunto ordenado de 8 bits.

Se puede ver entonces que, en lugar de trabajar con números en base 10, como lo hacemos en nuestra vida diaria, y en los cuales existen los símbolos del 0 al 9, las computadoras utilizan diferentes iteraciones del sistema binario esto es en base 2, que, como ya se ha mencionado, sólo contiene los símbolos 0 y 1.


Hay varias formas de representar un número en base 10 en base 2:

- BCD (o binario natural) es la conversión más sencilla, consiste simplemente en una conversión de base. Así pues el número “treinta y siete”, que en base 10 sería el “37”, en binario sería “100101”.

Para pasar de binario a decimal solo hay que multiplicar cada bit por una potencia de 2 correspondiente a su posición (de derecha a izquierda) y empezando por 0:

$$100101 = 1 \cdot 2^5 + 0 \cdot 2^4 + 0 \cdot 2^3 + 1 \cdot 2^2 + 0 \cdot 2^1 + 0 \cdot 2^0 = 32 + 4 + 1 = 37$$

El proceso contrario sería dividir el número por dos hasta que el resultado sea uno e ir cogiendo los restos de las operaciones anteriores:



- Signo y magnitud: se añade un bit a la izda. del número donde 0 representa que es positivo y 1 que es negativo. así pues, “37” sería “0100101” y “-37”, “1100101”
- Complemento a 2: es una forma más enrevesada a primera vista de obtener números enteros, pero que resulta mucho más fácil a la hora de realizar operaciones y por eso es más utilizada en sistemas informáticos.

Si quisiéramos hallar el complemento a 2 de 37 (esto es -37), la forma más sencilla sería invertir todos los dígitos del número (lo que se conoce como complemento a 1) y luego sumarle 1.

$00100101 \rightarrow 11011010 \rightarrow 11011011$

- Coma flotante: Para representar números reales normalmente se usa una notación científica, para el caso decimal:

$$0.37 = 37 * 10^{-2}$$

La coma flotante en binario se compone de 3 partes: un bit de signo para el número y así diferenciar entre 0.37 y -0.37, el exponente (normalmente un número en BCD), que representa la posición de la coma en binario, y la parte significativa o mantisa (puede ser binario natural o complemento a 2). Puesto que el primer bit de la mantisa siempre será 1 (excepto contadas excepciones) este bit no se suele guardar, aunque luego se trabaja con él en las operaciones (pasa de ser implícito a explícito).

Finalmente hay que comentar otro sistema de notación muy utilizado, el hexadecimal, o base 16, en el cual se representan con un solo símbolo los números del 1 al 15.

decimal	0	1	2	3	4	5	6	7
hex	0	1	2	3	4	5	6	7

BCD	0000	0001	0010	0011	0100	0101	0110	0111
decimal	8	9	10	11	12	13	14	15
hex	8	9	A	B	C	D	E	F
BCD	1000	1001	1010	1011	1100	1101	1110	1111

2. Introducción

Python fue creado a finales de los ochenta por [Guido van Rossum](#) en el Centro para las Matemáticas y la Informática (CWI, [Centrum Wiskunde & Informatica](#)), en los [Países Bajos](#), como un sucesor del [lenguaje de programación ABC](#), capaz de [manejar excepciones](#) e interactuar con el [sistema operativo Amoeba](#).⁵

El nombre del lenguaje proviene de la afición de su creador por los humoristas británicos [Monty Python](#).

Los usuarios de Python se refieren a menudo a la filosofía de Python que es bastante análoga a la filosofía de [Unix](#). El código que siga los principios de Python se dice que es "pythonico". Estos principios fueron descritos por el desarrollador de Python [Tim Peters](#) en [El Zen de Python](#)

- Bello es mejor que feo.
- Explícito es mejor que implícito.
- Simple es mejor que complejo.
- Complejo es mejor que complicado.
- Plano es mejor que anidado.
- Disperso es mejor que denso.
- La legibilidad cuenta.
- Los casos especiales no son tan especiales como para quebrantar las reglas.
- Lo práctico gana a lo puro.
- Los errores nunca deberían dejarse pasar silenciosamente,
- a menos que hayan sido silenciados explícitamente.
- Frente a la ambigüedad, rechaza la opción de adivinar.
- Debería haber una (y preferiblemente solo una) forma de hacerlo,
- Aunque esa manera no sea obvia de hacerlo, a menos que sea usted holandés.
- "Ahora" es mejor que "nunca",
- Aunque "nunca" es mejor que "ahora mismo".
- Si la implementación es difícil de explicar, es una mala idea.
- Si la implementación es fácil de explicar, probablemente sea una buena idea
- Los espacios de nombre (namespace) son una gran idea. Hagamos más de esas cosas.

En resumen, Python es un lenguaje de alto nivel con gramática sencilla, clara y muy legible. Cuenta con tipado dinámico y fuerte, es orientado a objetos e interpretado. Fácil de aprender, versátil y open source.

3. Instalación del entorno

a. Windows

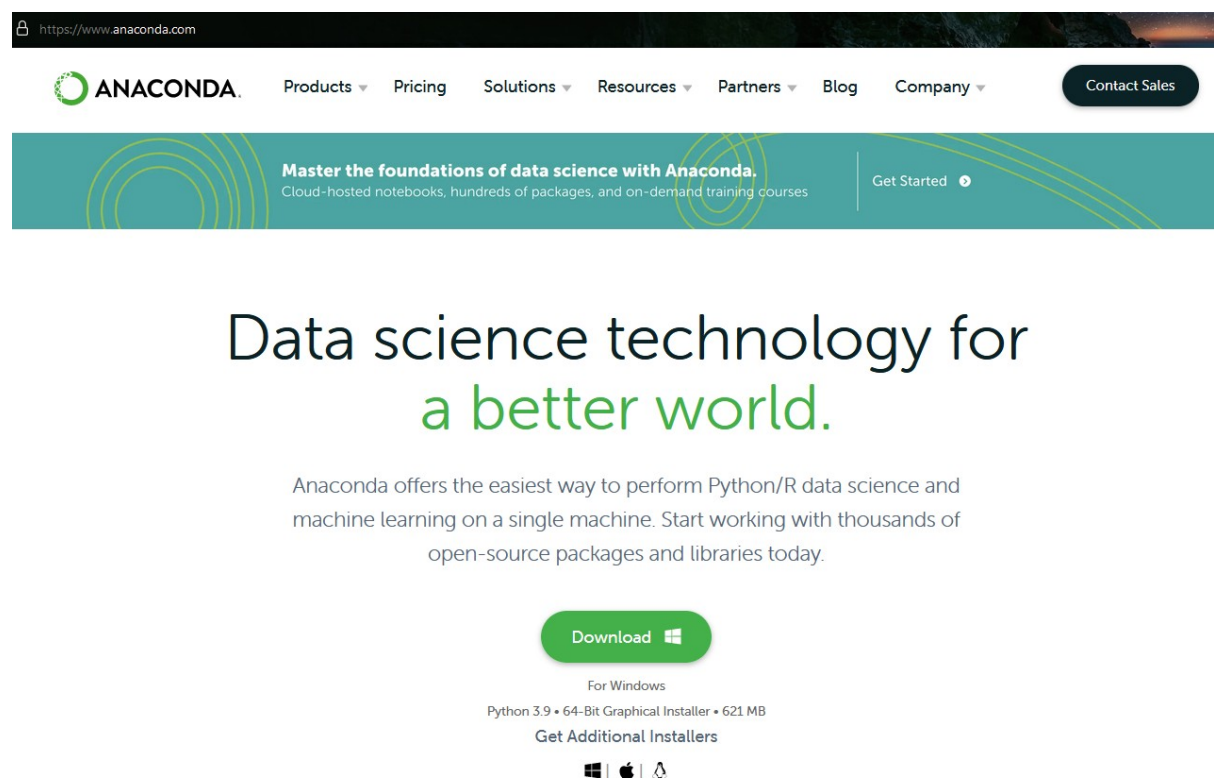
Instalación de Anaconda

Anaconda es una distribución gratuita de Python (así como del lenguaje R), que contiene una GUI (Graphical User Interface), llamada Anaconda Navigator, que nos permite acceder a diferentes aplicaciones de programación (como Spyder, JupyterLab, Visual Studio Code, etc.), así como acceder a la ventana de comandos (la CLI o Command-Line Interface) de anaconda, pudiendo crear diferentes entornos de python donde trabajar dependiendo de nuestras necesidades.

Instalación de Anaconda Navigator

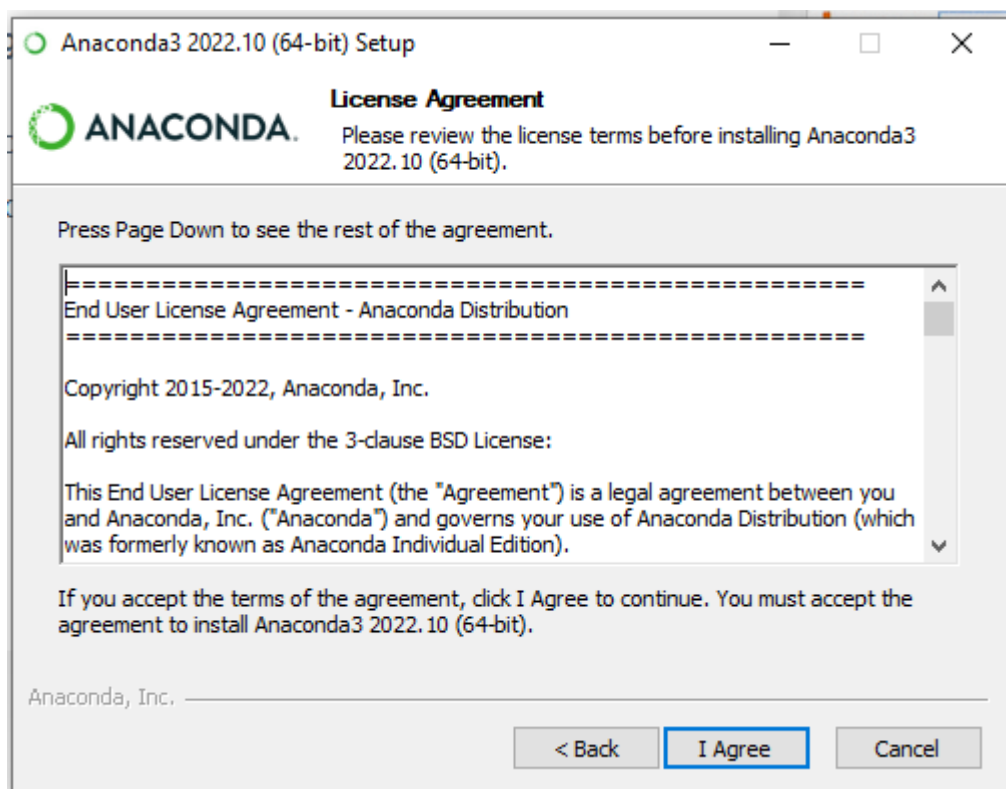
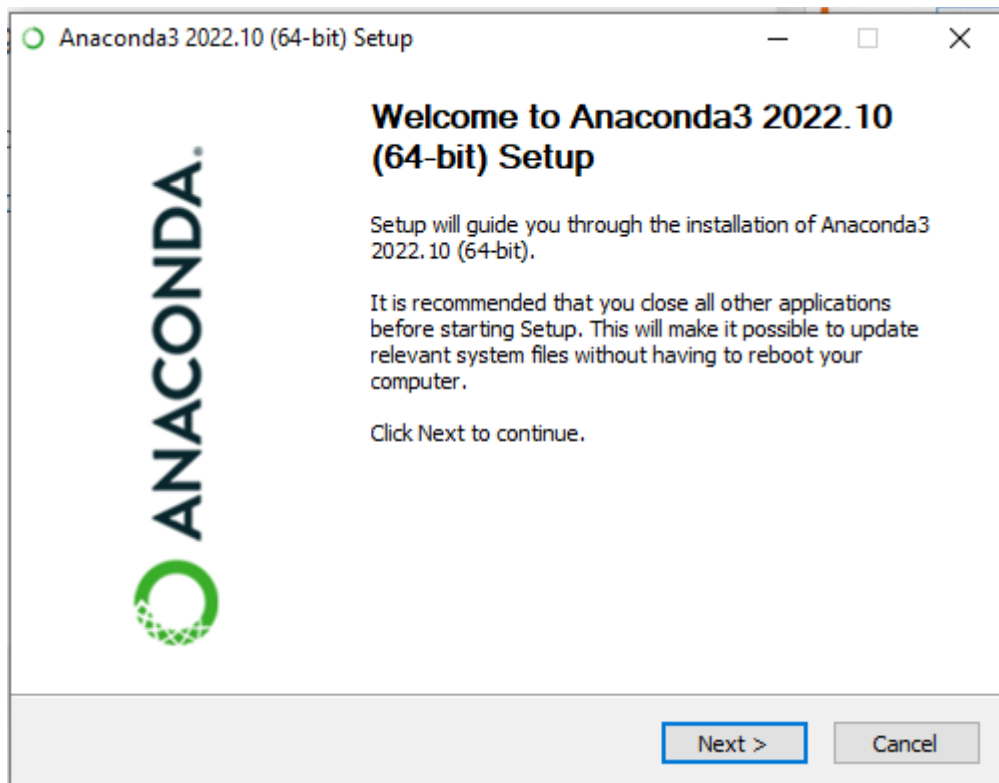
Para descargar el entorno, navegaremos aquí:

<https://www.anaconda.com/>

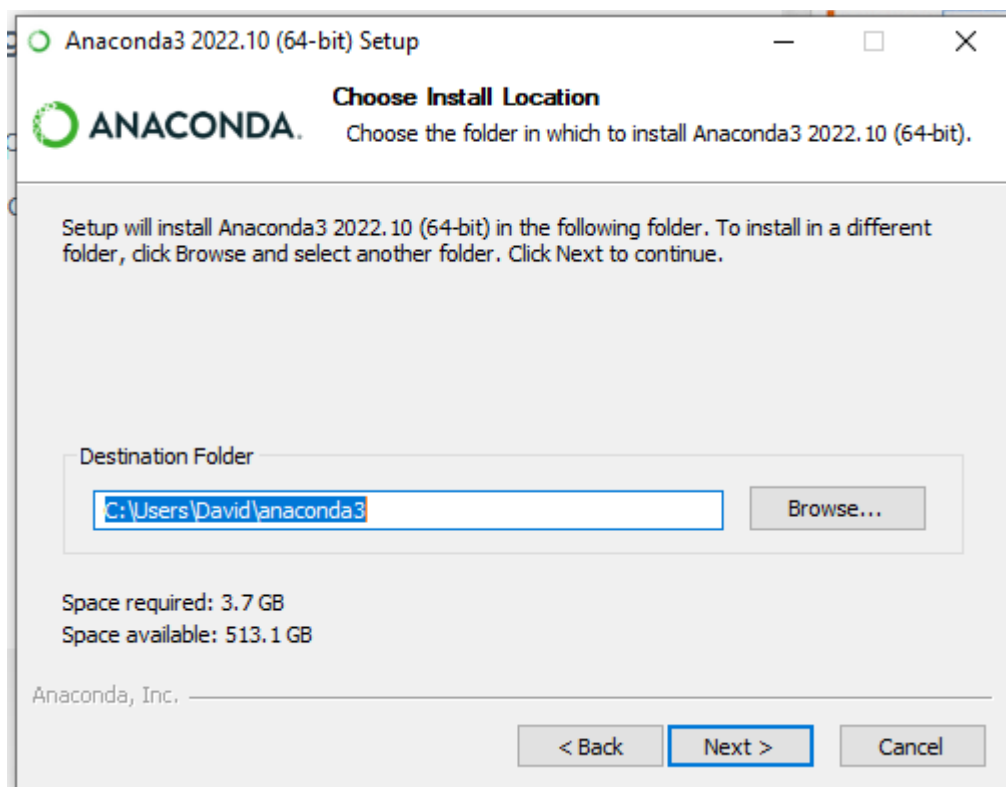



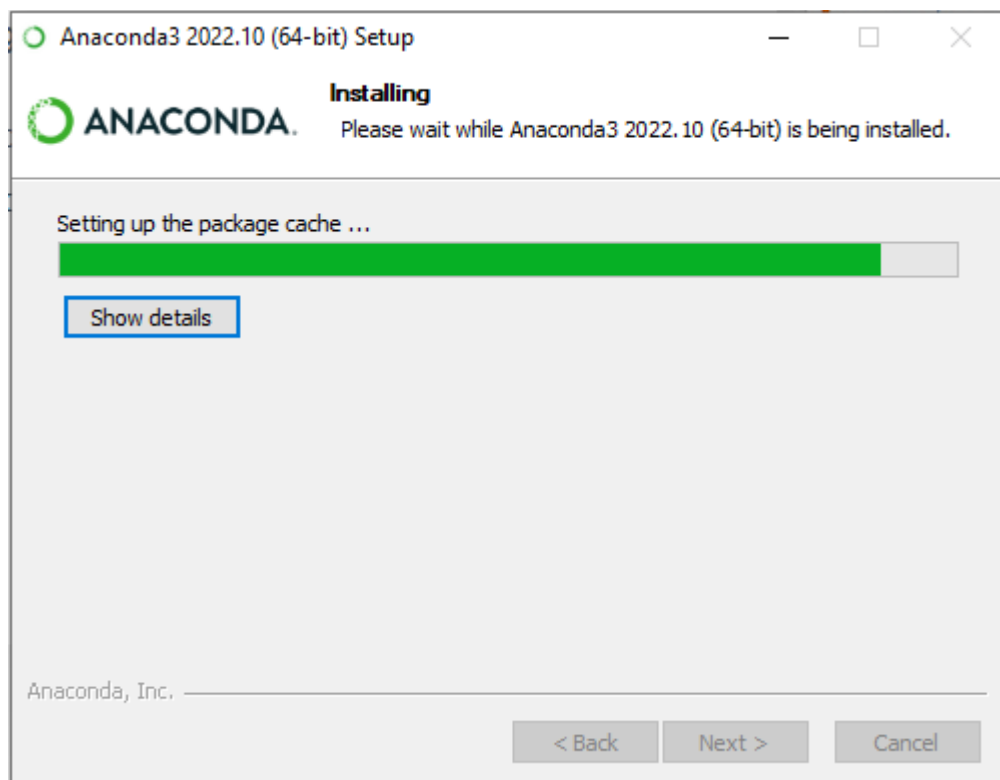
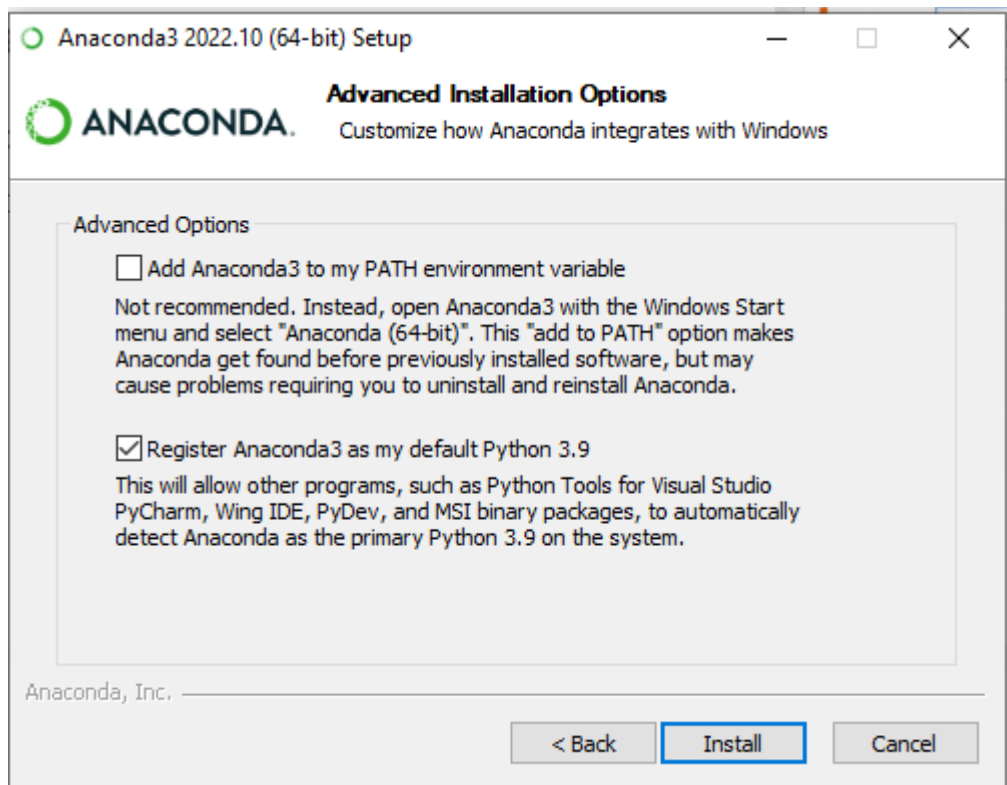
Haremos click en download y comenzaremos el proceso de instalación.

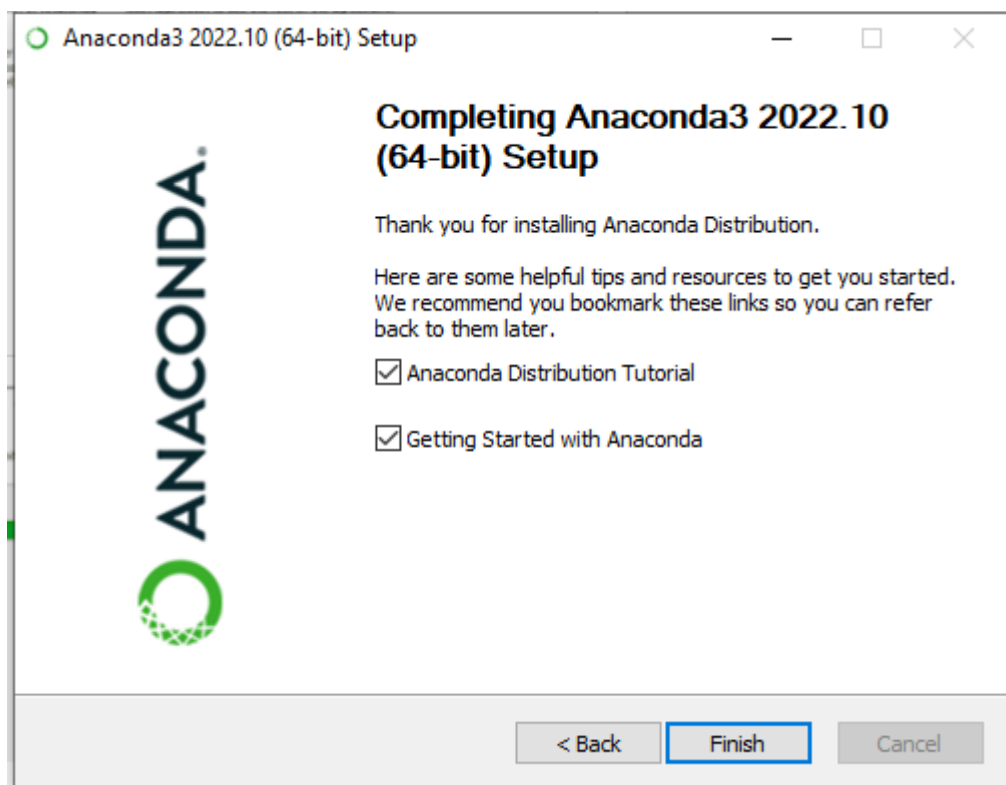
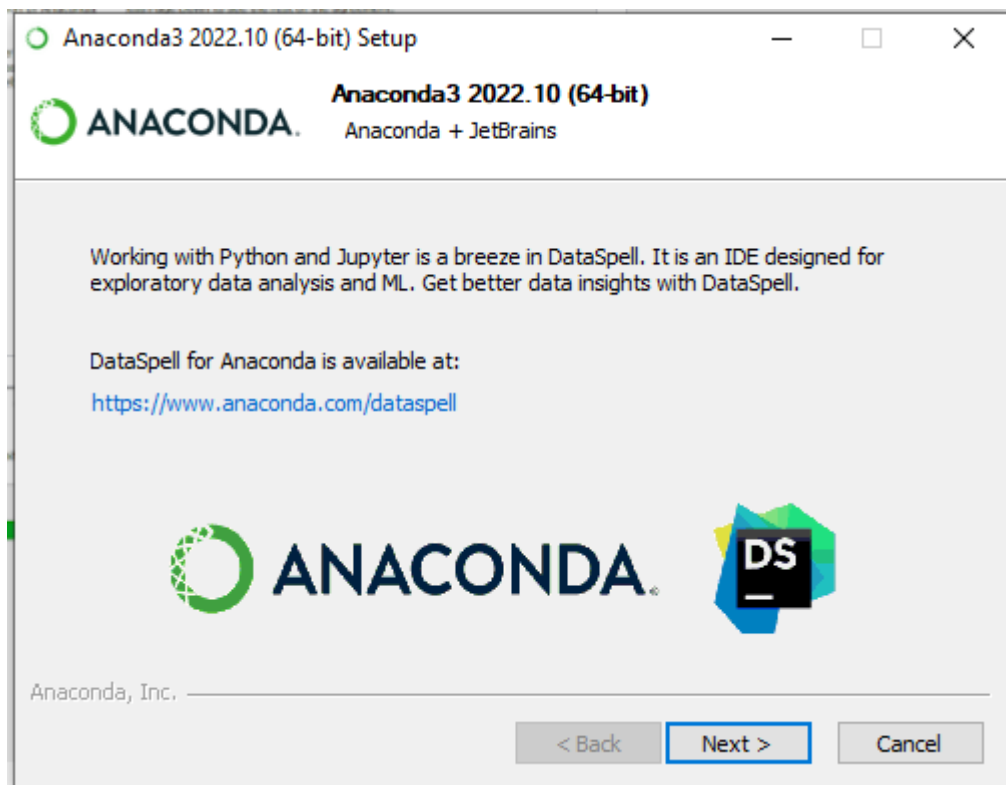
El proceso en sí es sencillo, podéis dejar las opciones por defecto o cambiarlas a vuestro gusto, igualmente aquí hay una pequeña guía visual del proceso:



Términos y condiciones de uso.

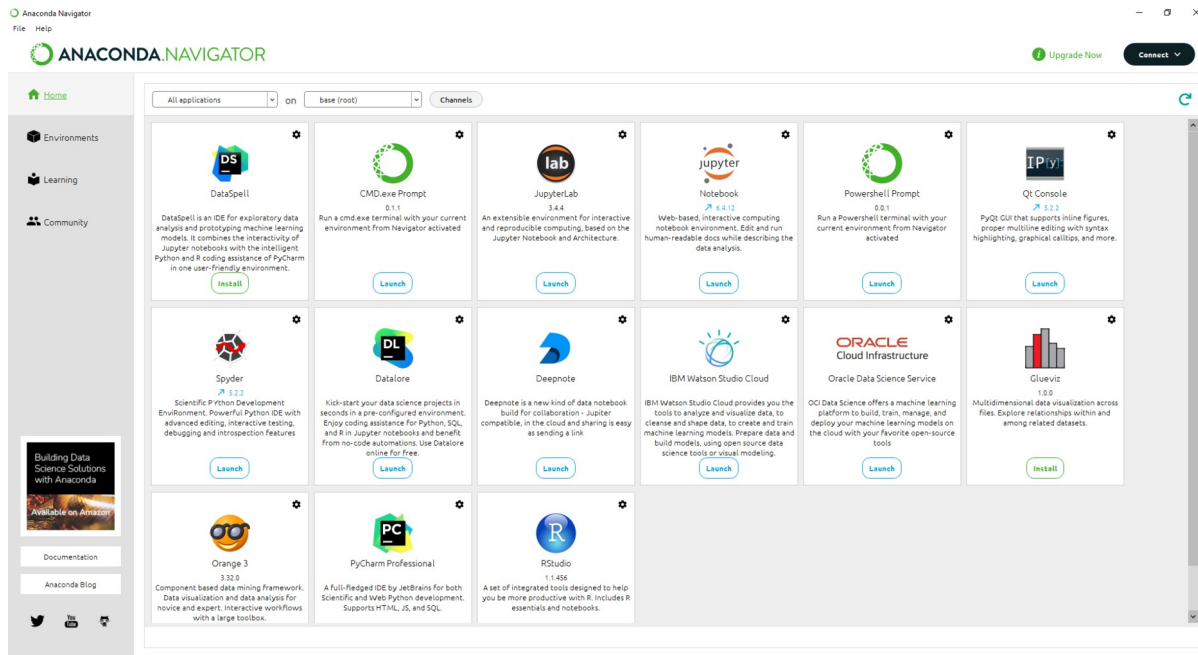






Después accederemos al navegador de anaconda. Si no hemos creado un acceso directo en el escritorio, lo podemos encontrar desde la barra de búsqueda de windows.

Una vez abierto, nos encontraremos con esta pantalla:



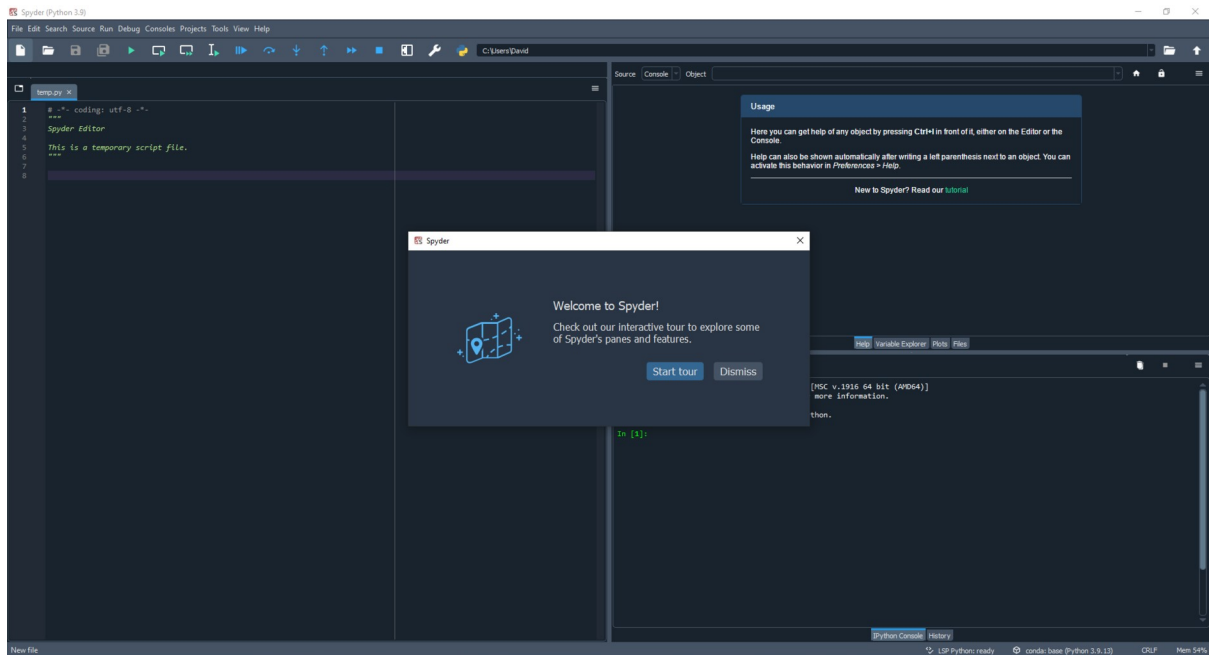
A la izquierda de la pantalla nos encontramos con un menú que contiene:

- **Home:** visualiza las aplicaciones instaladas para el actual entorno
- **Environments:** aquí podemos crear, modificar y borrar entornos de Python. Viene con uno creado por defecto. Estos entornos nos permiten encapsular los paquetes y distribuciones de python que necesitamos para diferentes formas de programación y así evitar conflictos, ya sea por versiones de los paquetes o el propio Python
- **Learning:** contiene una amplia serie de tutoriales
- **Community:** accesos directos a las principales páginas de ayuda en python (como StackOverflow)

Lanzando las aplicaciones

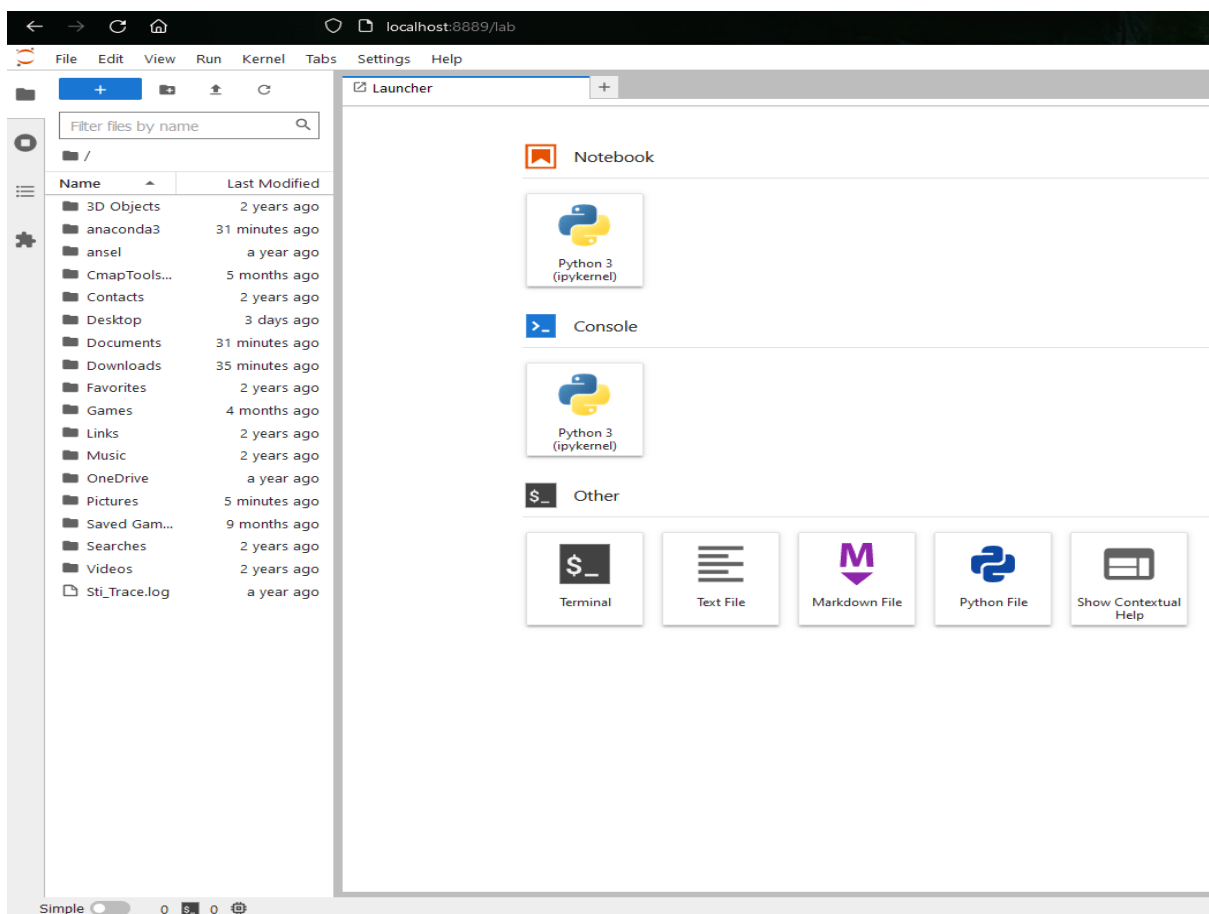
Por último, para comprobar que todo se ha instalado correctamente, lanzaremos tanto el Spyder como el JupyterLab (no confundir con Jupyter Notebook o simplemente llamado Notebook)

Al abrir el Spyder podremos acceder a un tutorial que nos mostrará las diferentes características de la aplicación.



Es muy recomendable seguir el tutorial para dominar las bases de Spyder

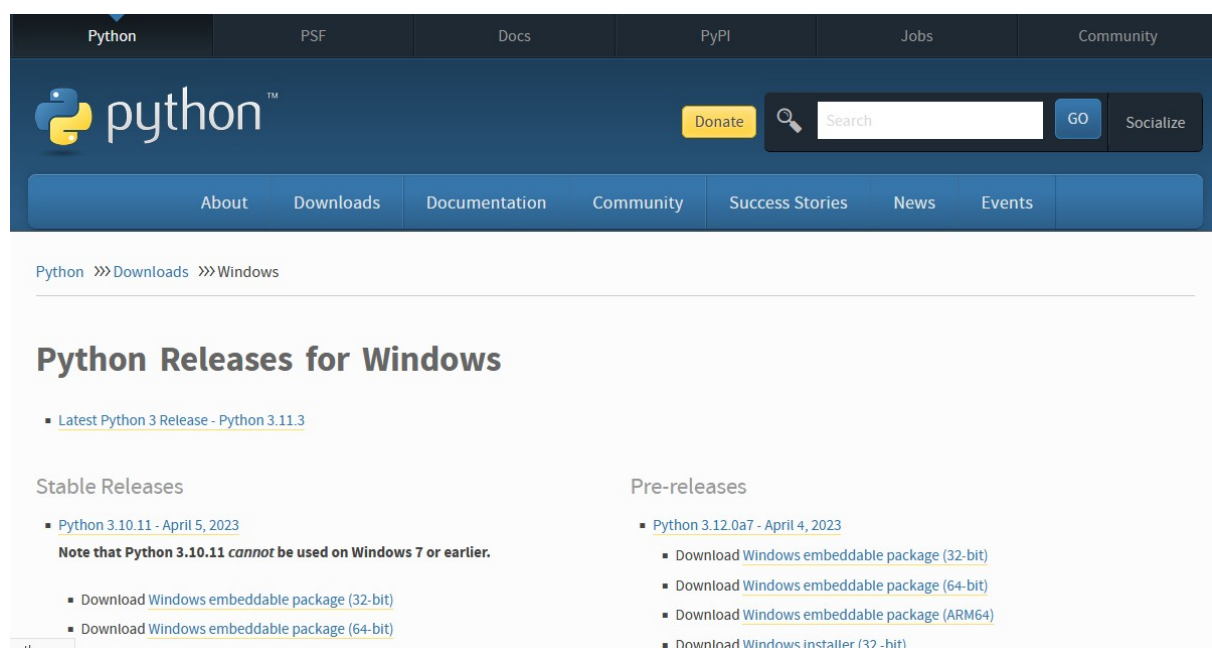
Por el contrario, cuando abrimos JupyterLab se nos abrirá una nueva pestaña en nuestro navegador por defecto.



Si nos fijamos, JupyterLab trabajará desde nuestra carpeta de usuario, por lo que es recomendable crear una carpeta donde guardar nuestros proyectos. Esto se puede hacer creando una carpeta directamente desde windows o creando desde el JupyterLab, haciendo click derecho en la ventana que nos muestra los directorios y archivos o, justo encima de la barra de búsqueda que se encuentra aquí, haciendo click en el símbolo de la carpeta con un “+” superpuesto.

Instalación de Python

Si quisiéramos trabajar con Python directamente desde nuestro sistema operativo Windows, podemos instalarlo sin necesidad de utilizar frameworks como Anaconda. Para ello iremos a la [página oficial de Python](#) y buscaremos la versión del lenguaje que más se adapte a nuestras necesidades.



Python >>> Downloads >>> Windows

Python Releases for Windows

- [Latest Python 3 Release - Python 3.11.3](#)

Stable Releases

- [Python 3.10.11 - April 5, 2023](#)
Note that Python 3.10.11 cannot be used on Windows 7 or earlier.
 - [Download Windows embeddable package \(32-bit\)](#)
 - [Download Windows embeddable package \(64-bit\)](#)

Pre-releases

- [Python 3.12.0a7 - April 4, 2023](#)
 - [Download Windows embeddable package \(32-bit\)](#)
 - [Download Windows embeddable package \(64-bit\)](#)
 - [Download Windows embeddable package \(ARM64\)](#)
 - [Download Windows installer \(32-bit\)](#)

Navegamos hasta la sección “Archivos” de la página y elegimos el ejecutable que queremos descargar para nuestro sistema operativo (seguramente uno de los dos últimos)

Files

Version	Operating System	Description	MD5 Sum	File Size	PGP	Sigstore
Gzipped source tarball	Source release		7e25e2f158b1259e271a45a249cb24bb	26085141	SIG	.sigstore
XZ compressed source tarball	Source release		1bf8481a683e0881e14d52e0f23633a6	19640792	SIG	.sigstore
macOS 64-bit universal2 installer	macOS	for macOS 10.9 and later	f5f791f8e8bfb829f23860ab08712005	41017419	SIG	.sigstore
Windows embeddable package (32-bit)	Windows		fee70dae06c25c60cbe825d6a1bfda57	7650388	SIG	.sigstore
Windows embeddable package (64-bit)	Windows		f1c0538b060e03cbb697ab3581cb73bc	8629277	SIG	.sigstore
Windows help file	Windows		52ff1d6ab5f300679889d3a93a8d50bb	9403229	SIG	.sigstore
Windows installer (32-bit)	Windows		83a67e1c4f6f1472bf75dd9681491bf1	27865760	SIG	.sigstore
Windows installer (64-bit)	Windows	Recommended	a55e9c1e6421c84a4bd8b4be41492f51	29037240	SIG	.sigstore

Ejecutamos el programa de instalación:



IMPOTANTE: chequear la casilla “Add python.exe to PATH” o habrá que añadir python al path de windows manualmente.

Después seguís las instrucciones y, una vez terminada la instalación, podemos

- b. IOS
- c. Linux

4. Bases del lenguaje

Cuando abrimos una shell de python, podemos empezar a introducir instrucciones, por ejemplo:

```
(base) C:\Users\User>python
Python 3.8.8 (default, Apr 13 2021, 15:08:03) [MSC v.1916 64 bit (AMD64)] :: Anaconda, Inc. on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> 2 + 2
4
>>>
```

Aquí hemos sumado $2 + 2$, esta instrucción es lo que se conoce como **expresión**, que consta de **valores** y **operadores**.

En el caso de Python, encontramos diferentes tipos de operadores, muy similares a los de otros lenguajes.

OPERADORES ARITMÉTICOS			
Símbolo	Nombre	Explicación	Ejemplo

+	suma		2 + 3 (=5)
-	resta		4 - 5 (=-1)
*	multiplicación		2 * 5 (=10)
/	división		10 / 4 (=2.5)
%	resto		8 % 3 (=2)
**	potencia		2**3 (=8)
//	división entera		8 // 3 (=2)

OPERADORES COMPARATIVOS

Símbolo	Nombre	Explicación	Ejemplo
==	Igualdad o equivalencia	Etor operadores devuelven un booleano (True / False) de la expresión que comparan. Por ejemplo: 3 == 2 >>> False 3 != 2 >>> True 3 < 2 >>> False	
!=	distinto		
>	mayor que		
<	menor que		
>=	mayor o igual que		
<=	menor o igual que		

OPERADORES LÓGICOS

Símbolo	Nombre	Explicación	Ejemplo
and	y	Son operadores lógicos que trabajan con variables booleanas, que normalmente son el resultado de expresiones con operadores comparativos. Por ejemplo: (x > 10) and (y == 20)	
or	o		
not	negado o no		

OPERADORES DE PERTENENCIA

Símbolo	Nombre	Explicación	Ejemplo
is		Devuelve True si ambos objetos son el mismo	
is not		Devuelve True si sendos objetos son diferentes	

OPERADORES DE MEMBRESÍA

Símbolo	Nombre	Explicación	Ejemplo
in		Devuelve True si el valor especificado está en el objeto	3 in x
not in		Devuelve True si el valor especificado no está en el objeto	3 not in x

OPERADORES DE ASIGNACIÓN			
Símbolo	Explicación	Ejemplo	Equivalencia
=	Operador asignación	x = 3	
+=		x += 3	x = x + 3
-=		x -= 3	x = x - 3
*=		x *= 3	x = x * 3
/=		x /= 3	x = x / 3
%=		x %= 3	x = x % 3
**=		x **= 3	x = x ** 3
//=		x //= 3	x = x // 3
&=	and (bitwise)	x &= 3	x = x & 3
=	or (bitwise)	x = 3	x = x 3
^=	xor	x ^= 3	x = x ^ 3
>>=	desplazamiento de bits a la dcha.	x >>= 3	x = x >> 3
<<=	desplazamiento de bits a la izda.	x <<= 3	x = x << 3

Además de los operadores, Python contiene una lista de caracteres especiales, sobre todo usados en las variables tipo string, y unas palabras reservadas que representan la base del lenguaje.

Caracter	Explicación	Ejemplo
\n	salto de línea	
\t	tabulación horizontal	
\r	vuelta de carro	
\b	borrar (backspace)	
\f	página siguiente (form feed)	

\'	comilla simple	
\"	comilla doble	
\\	backslash	
\v	tabulación vertical	
\UN	Caracter en Unicode, donde N es el número	'\U000000D1' es 'Ñ'
\NNN	Caracter donde NNN son dígitos en base octal	'\151' es 'i'
\xN	Caracter donde N son dígitos en base hexadecimal	'\x69' es 'i'
\a	sonido de campana del sistema	

así mismo, las palabras reservadas, donde también se cuentan algunos operadores, son:

Palabra	Significado	Palabra	Significado
False		global	para modificar una variable global dentro de una función
None		if	para hacer una declaración condicional, junto con 'else' y 'elif'
True		import	importar módulos completos
and	operador 'y'	in	
as	reasigna un objeto con un nuevo nombre	is	
assert	Utilizado para debugging, similar a la función print()	lambda	función anónima que puede tener cualquier número de argumentos, pero solo una expresión
break	Para salir de un bucle	nonlocal	para funciones dentro de funciones, declara que algo no es local.
class	para definir clases	not	
continue	saltar a la siguiente iteración del bucle	or	
def	definir función	pass	declaración nula, para añadir código en el futuro
del	borrar un objeto de la memoria	raise	obliga a lanzar un error
elif	equivalente a "else if"	return	salir de una función o método
else	acción alternativa a 'if' y 'elif'	try	parte del código que se intenta ejecutar
except	qué hacer en caso de excepción	while	declaración de un bucle while

	(Error, warning, etc.)		
finally	parte del (try/except), que obliga a ejecutar esta parte del código	with	se utiliza para simplificar el manejo de excepciones
for	definición del bucle for	yield	finaliza una función y devuelve el iterador
from	para incluir una parte específica de un módulo		

Con esto, podemos también ahora utilizar los tipos de dato predefinidos en Python

Categoría	Tipo	Explicación	Ejemplo
Texto	str	string o cadena de caracteres	x = 'hola' x = "hola"
Numérico	int	entero	x = 14
	float	coma flotante	x = 14.
	complex	número complejo (donde "j" es el imaginario)	x = 2 + 3j
Secuencia	list	lista (puede modificarse) de objetos que pueden ser de varios tipos	x = [2, 4, 9] x = ["uno", "dos"]
	tuple	tuple (no puede modificarse)	x = (4., 5.3, 7.)
	range	secuencia inmutable de números	x = range(10)
Mapeado	dict	guardan datos en parejas de "key": "value"	x = {"manzanas": 3, "peras": 17}
Set	set	guardan varios datos en una variable, pero los datos no pueden repetirse	x = {"peras", "manzanas", "piñas"}
	frozenset	set inmutable	
Booleano	bool	puede tener dos valores: True o False	x = True x = False
Binario	bytes	secuencia de enteros (de 0 a 255) inmutable	
	bytearray	igual que bytes pero admite cambios	
	memoryview	permite acceder el buffer interno de python de forma segura	
None	NoneType	Tipo nulo, sin valor	x = None

Es destacable también que los nombres del tipo de dato sirven a su vez para hacer conversiones y definiciones de los mismos, es decir, que podemos definir, por ejemplo, una lista de las siguientes formas:


```
x = list()
x = []
```

En ambos casos crearía una lista vacía, pero podemos concatenar la llamada de funciones:

```
x = [0, 1, 2, 3, 4, 5]
x = list(range(6))
```

Finalmente, para dejar comentarios en python tenemos dos opciones:

- `#` para comentarios de línea
- `"""(...)"""` para un bloque de comentario

Por ejemplo:

```
# Este comentario es de una línea
x = 37 # se pueden añadir comentarios después de una sentencia

""" Este es un comentario de bloque,
que tiene varias líneas,
pero no acaba hasta que se cierre la triple comilla"""
```

a. Control de flujo

Antes de hablar del control de flujo per se, hay comentar la importancia de la indentación y la definición de bloques de código en Python.

Un bloque de código es un conjunto de sentencias en un lenguaje de programación, que a su vez puede contener otros bloques de código dentro de ellos, es decir, que se pueden anidar bloques de código. En Python, tanto las clases, como el cuerpo de las funciones, como los módulos ejecutados o un archivo tipo `.py` se consideran bloques de código, es decir cualquier conjunto de sentencias bien definidas y delimitadas.

Además, a diferencia de en otros lenguajes, los bloques de código vienen dados por el número de tabulaciones que se encuentran antes de la sentencia. Por ejemplo:

```
x = 10
if x <= 10:
    x += 1
    print(x)
else:
    print("El numero es mayor que 10")
```

En este caso, un bloque de código sería la parte que se ejecuta si el número “x” es menor o igual que 10, otra parte si no lo es y total del código en su conjunto.

Dicho esto, podemos empezar con el control de flujo propiamente dicho en Python.

Python, al ser un lenguaje de programación secuencial, ejecutará de forma sistemática las sentencias que se le ordenen, pero a veces queremos que solamente se ejecuten ciertas partes dependiendo de las circunstancias, así pues, tenemos las instancias **if**, **elif** y **else**.

Una instancia **if** ejecutará el bloque de código contenida en su interior si la instancia de la que depende tiene como resultado un booleano de valor **True** (aunque a veces con la existencia de un tipo, que el valor sea distinto de 0 o con que este contenga al menos un elemento valdrá).

```
if (x > 10) and (y == 4):  
    (...) # esto solamente se ejecutará si x es mayor que 10 e y  
    es igual a 4
```

Por otro lado, a veces hay una dicotomía, en la que hay que elegir ejecutar una parte del código u otra, aquí usaremos el **else**:

```
if x == 25:  
    (...) # esto solamente se ejecutará si x es igual a 25  
else:  
    (...) # esto se ejecutará si x es distinto de 25
```

Finalmente, en ciertas ocasiones hay que elegir entre más de dos opciones, es ahí donde podemos usar la sentencia **elif** (abreviatura de **else if**).

```
if x == 25:  
    (...) # esto solamente se ejecutará si x es igual a 25  
elif x > 50:  
    (...) # esto se ejecutará si x es mayor que 50  
else:  
    (...) # esto se ejecutará si x es distinto de 25 y menor o  
    igual a 50
```

Es importante destacar, que en caso de cumplirse dos condiciones a la vez, se ejecutará solamente el código de la primera escrita, ya que python recorre las condiciones de forma secuencial.

Por otro lado, tenemos los bucles, que ejecutarán un bloque de código mientras sean ciertas las condiciones de su definición.

En python tenemos dos tipos de bucles: el bucle **while** y el **for**.

El bucle **while** se define de la siguiente manera:

```
while condition:  
    (...)
```

donde “condition” es una condición lógica que debe ser cierta para que se ejecute la siguiente iteración del bucle.

Por otro lado el bucle for itera sobre los elementos de una secuencia (una lista, tupla, diccionario, set o string) y se define:

```
for element in sequence:
    (...)
```

Donde “element” es cada elemento de la secuencia “sequence”.

Es importante destacar que, tanto los bucles como las instancias lógicas pueden estar anidados. Por ejemplo:

```
for i in range(10):
    if i < 5:
        for j in range(10):
            print(j)
    else:
        print("asd")
```

Por último tenemos dos sentencias de control en los bucles: **break** y **continue**. Break sirve para salir del bucle actual, mientras que continue salta directamente a la siguiente iteración sin ejecutar el resto de código de la iteración actual.

```
for i in range(1000):
    if i == 10:
        print("Numero 10")
        continue
    print(i)
    if i > 100:
        break
```

También podemos hacer uso de pass si queremos dejar un bucle vacío para ser rellenado más adelante para evitar que salte un error:

```
for elem in element_list:
    pass
```

b. Listas, diccionarios y strings

Dentro de los tipos secuenciales, las listas, los diccionarios y las string son los más utilizados.

Tanto estos tipos secuenciales como el reto no mencionados en esta sección tienen acceso a una serie de funciones y operadores comunes, así como una lógica de acceso a sus elementos internos similar. Pongamos, por ejemplo la cadena:

```
x = 'hola mundo'
x = "hola mundo"
```

En este caso, el índice de los elementos sería:

x	h	o	l	a		m	u	n	d	o
índice incremental	0	1	2	3	4	5	6	7	8	9
índice decremental	-10	-9	-8	-7	-6	-5	-4	-3	-2	-1

Así pues, podemos acceder a los elementos de la cadena utilizando los corchetes “[” y “]”

```
x[0] # accede al primer elemento
x[-1] # accede al último elemento
x[i:j] # accede a los elementos de i a j-1
x[i:j:n] # accede a los elementos de i a j-1 de n en n
x[:j] # accede a los elementos desde el primero hasta el anterior a j
x[j:] # accede a los elementos desde el j hasta el final
x[-k:] # accede a los últimos k elementos
x[-k:-1] # accede a los elementos desde -k hasta el anterior a -1
```

Un operador utilizado frecuentemente es el de concatenación, es decir, “+” y “+=”.

```
x += ' que tal?' daría la cadena 'hola mundo que tal?'
```

Algunas funciones que comúnmente se utilizan son **len()** e **index()**.

len(x) da la longitud del objeto según su número de elementos.

x.index(elem) es un método que devuelve el índice del elemento elem

Como ya se ha mencionado anteriormente, un string es una cadena de caracteres, es decir, un conjunto de varios caracteres alfanuméricos dentro del estándar Unicode. Podemos inicializar o definir un string por medio de las comillas simples o dobles, pues Python no realiza distinción alguna entre ambas.

```
x = 'hola mundo'
x = "hola mundo"
```

A su vez, la función str() permite convertir un tipo de dato a una string

```
n = 17
x = str(n)
```

En cuanto a los métodos propios de la clase string, nos encontramos con algunos muy típicos:

método	explicación	ejemplo
capitalize()	pone la primera letra de la string en	str.capitalize()

	mayúscula	
casefold()	convierte la string a minúsculas	
count()	número de veces que una string aparece en otra	
endswith()	devuelve True si la string acaba con los caracteres especificados	
find() index()	devuelven la posición de un elemento, que no se sabe si existe en la cadena en el caso de find()	
join()	une los elementos de un iterable según la cadena	' '.join(list_of_words)
strip() lstrip() rstrip()	quita los caracteres especificados de la cadena (por defecto el caracter espacio), en el caso de lstrip() y rstrip() los quita de l principio y del final de la cadena respectivamente	
split() splitlines()	divide la cadena de caracteres por el espacio (u otro caracter) o el salto de línea ('\n') respectivamente	

Para ver el resto de métodos que corresponden a la clase string:

<https://docs.python.org/3/library/stdtypes.html#string-methods>

https://www.w3schools.com/python/python_strings_methods.asp

Las listas, por otro lado, se definen de la siguiente forma:

```
x = [1, 2, 3]
x = list(1, 2, 3)
```

Una lista puede contener elementos de cualquier tipo, incluso otras listas, lo que formaría una matriz. en este caso se puede acceder a cada elemento de la siguiente forma:

```
x[i] # accede al elemento tipo lista en la posición i
x[i][j] # accede al elemento j de la lista i
```

Se pueden aplicar las reglas de indexación explicadas anteriormente:

```
x[i:j][k:l] accede a los elementos de k a l de las listas de i a j
```

Es importante denotar que, al igual que no todos los elementos de una lista tienen por qué tener la misma longitud, tampoco tienen por qué tener la misma longitud, por lo que es importante tener cuidado para no acceder a elementos inexistentes:

```
x = [[1, 2, 3], [4, 5], [6, 7, 8, 9, 10]]
```

Las listas, a su vez, tienen una serie de métodos propios de su clase:

Método	Explicación	Ejemplo
append()	añade un elemento a la lista	
clear()	borra todos los elementos de la lista	
copy()	devuelve una copia de la lista	
count()	devuelve el número de elementos	
extend()	añade varios elementos a la lista, es equivalente a <code>+</code> o <code>+=</code>	<code>lst_1.extend(lst_2)</code> <code>lst_1 += lst_2</code>
index()	devuelve el índice de un elemento	
insert()	inserta un elemento en la posición especificada	
pop()	elimina el elemento de la posición especificada	
remove()	elimina el elemento que coincide con lo que se le pasa	
reverse()	da la vuelta a la lista	
sort()	ordena la lista según un criterio	

Por último, los diccionarios son un tipo de dato complejo que contienen información en parejas de **key:value**, esto es, de clave:valor. Por ejemplo:

```
alumno = {"nombre": "Paco",  
          "apellido": "García",  
          "edad": 20}
```

Para crear y definir un diccionario podemos hacerlo directamente o ir añadiendo sus campos uno a uno:

```
alumno = {} # o bien alumno = dict()  
alumno['nombre'] = "Paco"  
alumno['apellido'] = "García"  
alumno['edad'] = 20
```

Indirectamente, podemos ver aquí la forma de acceder a los elementos de un diccionario, que, en lugar de con un número entero, es con el nombre de la clave, mientras que, para ir añadiendo campos nuevos al diccionario solamente tenemos que definirlos con una clave nueva.

Así pues, tenemos también una lista de métodos de diccionario que podemos utilizar:

Método	Explicación	Ejemplo
clear()	borra todos los elementos del diccionario	
copy()	devuelve una copia del diccionario	
fromkeys()	devuelve un diccionario con las claves especificadas y sus valores	
get()	devuelve el valor de la clave especificada	
items()	devuelve una lista de tuplas de la forma (key, value)	
keys()	devuelve una lista de las claves	
pop()	elimina el elemento de la clave especificada	
popitem()	elimina la última pareja de clave y valor insertada	
setdefault()	devuelve el valor de la clave especificada, si no existe, la crea con el valor especificado	
update()	actualiza el diccionario con las claves y valores dados	
values()	devuelve una lista de los valores del diccionario	

Es muy común, a su vez, iterar sobre listas, diccionarios o string, lo cual normalmente se hace por medio de un bucle for. Por ejemplo, para sacar por pantalla los elementos de una lista, podemos:

```
for i in range(len(elem_list)):  
    print(elem_list[i])
```

Pero, teniendo en cuenta que podemos iterar sobre una lista, es más simple hacer:

```
for elem in elem_list:  
    print(elem)
```

Sin embargo, si queremos trabajar con los elementos de una lista, podemos usar:

```
for elem in elem_list:
    if elem % 2 == 0:
        even_list.append(elem)
```

Sin embargo, Python permite trabajar con listas en una sola línea, lo cual, en aras de la legibilidad, puede ser preferible. Para el ejemplo anterior, sería:

```
even_list = [elem for elem in elem_list if elem % 2 == 0]
```

Es importante saber que la sintaxis de una línea para un condicional if y para un if/else son diferentes.

```
out_lst = [value for elem in in_lst if condition]
out_lst = [value if condition else default_value for elem in in_lst]
```

Por ejemplo:

```
in_lst = list(range(10))
out_lst_1 = [elem for elem in in_lst if elem % 2 == 0]
out_lst_1 = ['par' if elem % 2 == 0 else 'impar' for elem in in_lst]
```

Esto viene a su vez de la capacidad de poner expresiones condicionales en una sola línea:

```
n = 10
if n % 2 == 0:
    m = 'par'
else:
    m = 'impar'
```

Sería equivalente a:

```
m = 'par' if n % 2 == 0 else 'impar'
```

c. Funciones

Las funciones son bloques de código que solamente se ejecutan cuando son llamadas explícitamente.

Además de las funciones que contiene Python, nosotros podemos definir nuestras propias funciones utilizando **def**.

```
def funcion():
    print("Soy una funcion")
```

Para llamar a dicha función tenemos que ejecutar la sentencia:

```
funcion()
```


Además, a una función podrán pasársele diferentes tipos de argumentos o parámetros para que trabaje con ellos.

Los argumentos de palabra clave son aquellos de los cuales estamos obligados a pasar un valor para la ejecución de la función:

```
def funcion(arg1, arg2):
    print(arg1, "y", arg2)

funcion(4, "blabla")
```

Estos argumentos, a su vez, pueden tener valores por defecto para el caso de que no queramos pasarle siempre un valor o haya un valor que se use comúnmente.

```
def funcion(arg1, arg2 = "hola"):
    print(arg1, "y", arg2)

funcion(4)
```

Los argumentos con valores por defecto deberán ir siempre detrás de aquellos que no lo tienen.

Por otro lado, si desconocemos el número de parámetros que se le va a pasar a una función, podemos hacer uso de los ***args** y ****kwargs**. Los ***args** son los argumentos arbitrarios (arbitrary arguments) y, con ellos, la función recibirá una tupla de argumentos, mientras que con los ****kwargs**, o argumentos arbitrarios de palabras clave (keywords arbitrary arguments) la función recibe un diccionario de argumentos con sus palabras clave)

```
def receta(*ingredientes):
    for elem in ingredientes:
        print(elem)
receta("pasta", "tomate", "queso")

def nombre_completo(**kwargs):
    print("apellido:" kwargs['apellido'])
nombre_completo(nombre = 'Paco', apellido = 'García', edad = 20)
```

También es importante el uso de la palabra reservada **return**, por el cual la función devolverá uno o varios elementos, ya sean valores concretos o expresiones.

```
def suma_3(x):
    return x + 3

print(suma3(2))
```

También se pueden devolver expresiones lógicas o varios argumentos, por ejemplo:

```
def paridad(n):
    return 'par' if n % 2 == 0 else 'impar'
```

```
def mayores_que_100(x, y):  
    return x > 100 and y > 100
```

Es necesario aclarar que, aunque la expresión del return no es necesaria para la correcta definición de una función, sí que puede ayudar a delimitar el código mientras se escribe y no da error devolver nada

Una función podrá llamarse a sí misma en lo que es conocido como recursión, pero es una estrategia arriesgada, pues es fácil caer en bucles infinitos.

```
def funcion(i):  
    if i > 10:  
        return  
    i += 1  
    print(i)  
    funcion(i)  
funcion(0)
```

Es, a su vez, una buena práctica el intentar evitar hacer demasiadas anidaciones, para que así el código quede lo más limpio posible.

Es posible definir una función dentro de otra función, lo que se conoce como funciones anidadas. Esta función interna estará dentro del namespace de la función superior, por lo que solamente podrá ser llamada desde dentro de la misma.

```
def funcion_1():  
    def funcion_2():  
        ...  
        return  
  
    funcion_2()  
    return  
  
funcion_1()  
funcion_2() # Dará error, pues no está definida fuera del  
            namespace de funcion_1
```

5. Tratamiento de archivos

Un archivo es un conjunto de datos guardados en una serie de posiciones dentro de una memoria no volátil, que puede ser creado, accedido, leído y editado si se cumplen ciertas condiciones.

Para trabajar con archivos, Python proporciona una serie de funciones que permiten crearlos, abrirlos, leerlos, editarlos, cerrarlos y borrarlos.

Podemos abrir (o crear) un archivo por medio de la función `open()`, la cual admite 3 argumentos principalmente, el primero es el nombre del archivo, el segundo el modo de apertura y el tercero la codificación del archivo (por defecto 'utf-8').

```
open(file, mode='r', buffering=-1, encoding=None, errors=None,
      newline=None, closefd=True, opener=None)
```

El nombre del archivo también deberá contener su path en caso de que este esté en una o directorio diferente al actual.

Modo	Nombre	explicación	ejemplo
"r"	read	Valor por defecto. Abre el archivo para leerlo	f = open("example.txt") f = open("example.txt", 'r')
"a"	append	Abre para añadir al final, si no existe, crea el archivo	f = open("example.txt", 'a')
"w"	write	Abre para escribir, si no existe, crea el archivo	f = open("example.txt", 'w')
"x"	create	Crea el archivo, da error si ya existe	f = open("example.txt", 'x')
"t"	text	Modo texto (para archivos de texto). Añadido a 'r', 'a', 'w', 'x'	f = open("example.txt", 'rt')
"b"	binary	Modo binario (para otro tipo de archivos). Añadido a 'r', 'a', 'w', 'x'	f = open("example.png", 'rb')
"+"	update	Abre un archivo para ser actualizado	f = open("example.png", 'r+b')

Es importante que, si se abre un archivo, se cierre después de realizar las operaciones necesarias con él. Esto puede hacerse explícitamente por medio del método **close()** de la clase archivo, o implícitamente por medio de la palabra reservada **with**:

```
f = open("example.txt", 'r')
(...)
f.close()
```

```
with open("example.txt", 'r') as f:
    (...)
```

En ambos casos se hará lo mismo.

Además, la clase file (archivo) posee una serie de métodos que permiten modificar el contenido del mismo.

Método	Explicación
--------	-------------

close()	cierra el archivo
detach()	devuelve un raw stream separado para el buffer
fileno()	devuelve un número que representa el buffer interno, desde el punto de vista del sistema operativo
flush()	limpia el buffer interno
isatty()	devuelve si el archivo es interactivo o no
read()	devuelve el contenido del archivo
readable()	devuelve si el archivo es legible o no
readline()	lee una línea del archivo
readlines()	crea una lista con las líneas del archivo
seek()	cambia la posición del puntero del archivo
seekable()	devuelve si es posible cambiar la posición de dicho puntero
tell()	devuelve la posición actual del puntero en el archivo
truncate()	redimensiona el archivo a un tamaño determinado
writable()	devuelve si se puede escribir en el archivo
write()	escribe una string en el archivo
writelines()	escribe una lista de strings en el archivo

Veamos tres ejemplos de cómo trabajar con la lectura, escritura y añadido de datos a los archivos:

```
with open("file1.txt", 'rt') as f:
    lines = f.readlines()
for i, line in enumerate(lines):
    print(i, line)

lines = ["line1\n", "line2\n", "line3\n"]
line_extra = "extra line"
with open("file2.txt", 'wt') as f:
    f.writelines(lines)
    f.write(line_extra)

with open("file3.txt", 'a+') as f:
    f.write("\nNEW LINE\n")
```

6. Clases y objetos

a. Introducción

La programación orientada a objetos (OOP) es un paradigma de programación que se basa en los “objetos”. Un objeto consta de un estado (datos que almacena) y de un comportamiento (tareas o funciones que puede realizar), así como de una identidad que lo diferencia de otros objetos.

Algunas de sus propiedades principales son:

- **Abstracción:** no es necesario conocer el funcionamiento interno de un objeto para utilizar sus métodos.
- **Encapsulamiento:** toda la información relevante sobre un objeto está dentro del mismo.
- **Polimorfismo:** puede utilizarse el mismo nombre para llamar a comportamientos distintos en objetos distintos (por ejemplo, sobreescritura de operadores).
- **Herencia:** una clase puede heredar las propiedades de otra clase superior.
- **Modularidad:** la aplicación puede dividirse en partes más pequeñas tan independientes como sea posible del resto
- **Principio de ocultación:** cada objeto está aislado del resto y se relacionan a través de interfaces, evitándose así modificaciones por parte de usuarios no autorizados
- **Recolección de basura:** los objetos se destruyen automáticamente y liberan memoria.

b. Namespaces

Antes de hablar de clases y objetos, debemos definir dos conceptos en Python: los namespace y el scope.

Es bien sabido que Python es un lenguaje de programación orientado a objetos y en el cual todo lo que utilizamos es un objeto de una clase, por ejemplo, los tipos de datos en Python son en realidad clases, que contienen una serie de atributos y métodos.

Un **nombre**, o **identificador**, es aquello con lo que llamamos a un objeto en concreto. Por ejemplo, si tenemos la simple sentencia:

```
a = 2
```

En este caso, “2” sería el objeto creado y “a” el nombre asociado con él. Para poder observar su posición en memoria utilizaremos la función **id()**, de forma que si aplicamos dicha función a “a” y a “2” deberíamos obtener el mismo resultado, ergo ambas se refieren al mismo objeto.

```
print(id(a))  
print(id(2))
```

Pongamos ahora una serie de sentencias:

```
a = 2
```

```

print(id(a))
print(id(2))

a = a + 1
print(id(a))
print(id(3))

b = 2
print(id(b))
print(id(2))

```

Así podremos observar una serie de cambios a lo largo de las tres sentencias principales.

- En “a = 2”, se crea el objeto “2” y se le asocia como nombre “a”.
- En “a = a + 1”, se crea un nuevo objeto, “3”, y a pasa “a” ser su nombre, es decir que cambia de ser el nombre de “2” a ser el nombre de “3”.
- Finalmente, 2 no se ha eliminado de memoria, sigue por ahí flotando, y le asociamos un nuevo nombre, “b”. De forma que “a” sigue siendo el nombre de “3” y “b” es ahora el nombre de “2”.

Pero no solo los objetos de datos se benefician de esta propiedad de Python, las funciones que definimos son, a su vez, objetos también, de forma que puede asignárseles un nombre nuevo.

```

def funcion(n):
    print(f"pasado {n}, devolviendo {n**2}")
    return n**2
a = funcion
y = a(4)
print(y)

```

Así pues, un **namespace** es el conjunto de nombres definidos para objetos concretos. En Python pueden coexistir diferentes namespaces, aunque están aislados unos de otros. Cuando iniciamos el intérprete de Python, se crea un primer namespace general, que es el que permite que tengamos acceso a las diferentes utilidades propias del lenguaje (como usar funciones básicas del estilo `print()`). Por otro lado, cada módulo contiene su propio namespace, que importamos a un script al importar el módulo. Es cada script definimos, a su vez, nuestro propio namespace, así como namespaces locales dentro de las utilidades e nuestro script, como en las funciones.

Sin embargo, aunque tengamos todos estos namespaces dentro de nuestro script, no siempre podremos acceder a ellos desde ciertas partes del programa. En esencia, un scope es una parte de un programa desde la que se puede acceder a los nombres de un namespace sin necesidad de prefijos.

Por ejemplo:

```

def funcion_1():
    a = 20

```

```

def funcion_2():
    a = 30
    print("a =", a)
    funcion_2()
    print("a =", a)

a = 10
funcion_1()
print("a =", a)

```

En esta función, hay 3 variables llamadas "a" que pertenecen a 3 namespaces diferentes:

1. a = 10: pertenece al namespace global del programa
2. a = 20: pertenece al namespace de funcion_1
3. a = 30: pertenece al namespace de funcion_2

Sin embargo, si en cada caso utilizamos la palabra reservada "global", podemos acceder a los namespaces de niveles superiores:

```

def funcion_1():
    global a
    a = 20
    def funcion_2():
        global a
        a = 30
        print("a =", a)
    funcion_2()
    print("a =", a)

a = 10
funcion_1()
print("a =", a)

```

En este caso, las tres "a" tendrán el mismo valor, pues estamos usando el nombre de una variable de un namespace superior dentro de cada una de las funciones.

c. Clases y objetos

Volviendo al tema que nos incumbe. Un **objeto** puede contener dos tipos de **atributos**: **métodos** y **propiedades**. Las propiedades son variables internas del objeto, mientras que los métodos son funciones propias del objeto.

```

class Five:
    x = 5
    def suma(self, y):
        return self.x + y

obj = Five()

```

```
print(obj.suma(3))
```

En Python, el constructor de la clase se realiza con el método `__init__()` que tienen todos los objetos. Si lo declaramos explícitamente podemos además modificarlo para que inicialice el objeto de la forma que nosotros queremos.

```
class Persona:
    especie = 'homo sapiens'

    def __init__(self, edad, nombre, apellido, apodo = ""):
        self.edad = edad
        self.nombre = nombre
        self.apellido = apellido
        self.apodo = apodo
    def saludar(self):
        print("hola!")

per1 = Persona(30, 'Jorge', 'Jiménez', 'el pelos')
per2 = Persona(20, 'Gustavo', 'Gutiérrez')
```

Si queremos que al llamar directamente al objeto, nos salga por pantalla cierta información del mismo, podemos hacer uso de la función `__str__()`. Para el caso anterior, dentro de la definición de la clase pondríamos:

```
def __str__(self):
    return f"{self.nombre} {self.apellido} {self.edad}"
```

De forma que al hacer:

```
print(per1)
```

Salga por pantalla:

```
Jorge Jiménez 30
```

Estas funciones con doble barra baja son lo que se conoce como los Métodos Especiales de Python, a veces también llamados métodos dunder (de “double underscore”). Estos métodos pueden invocar sintaxis especiales de Python y son la forma que tiene este lenguaje de sobrecargar operadores. Por ejemplo, pongamos que definimos una clase similar a una lista, para poder acceder a cada uno de sus elementos, podemos sobrescribir la función `__getitem__`, pudiendo usar así la sintaxis `objeto[i]`. Viendo un ejemplo más visual, las dos siguientes sintaxis serían equivalentes:

```
x = list(...)
print(x[index])
print(x.__getitem__(index))
```


Para sobrescribir un operador en python y poderlo utilizar de la forma que queramos con nuestra clase, tendremos que acceder al método especial del operador en la definición de la clase. Por ejemplo, si definimos una clase vector y luego queremos sumar dos vectores de esa clase, crearíamos algo así:

```
class vector():
    def __init__(self, x, y, z):
        self.x = x
        self.y = y
        self.z = z
    def __add__(self, other):
        if isinstance(other, int) or isinstance(other, float):
            # Si other es un int o un float lo sumamos a cada
            # miembro
            x = self.x + other
            y = self.y + other
            z = self.z + other
            # devolvemos un nuevo vector
            return vector(x, y, z)
        if isinstance(other, vector):
            # si other es de la clase vector sumamos self y
            # other término a término
            x = self.x + other.x
            y = self.y + other.y
            z = self.z + other.z
            # devolvemos un nuevo vector
            return vector(x, y, z)
```

Así, ahora podemos usar:

```
a = vector(1,2,3)
b = vector(4,5,6)
print(a + b)
```

Todos los métodos especiales se encuentran en la documentación de Python:

<https://docs.python.org/3/reference/datamodel.html#special-method-names>

Se pueden crear además clases que heredan las propiedades de otra. Continuando con el ejemplo de los estudiantes, podemos definir una nueva clase “estudiante”, que hereda de persona. En una clase heredada podemos cambiar los métodos de la clase madre, así como añadir unos nuevos.

```
class Estudiante(Persona):
    universidad = "Complutense"
    def __init__(self, edad, nombre, apellidos, matricula):
        Persona.__init__(self, edad, nombre, apellidos)
```

```

        self.matricula = matricula
    def saludar(self):
        print("Ahora no tengo tiempo, que tengo exámenes")
    def despedirse(self):
        print("Adios!")

```

Para llamar a los métodos de la clase madre, podemos usar la sentencia `super`, de forma que, por ejemplo, el constructor quedase:

```

def __init__(self, edad, nombre, apellidos, matricula):
    super().__init__(edad, nombre, apellidos)
    self.matricula = matricula

```

Se puede dar el caso de herencia múltiple, en la cual una clase herede de más de otra clase, ya sea porque a su vez la madre es una clase heredada de otra, o porque se hereda directamente de varias clases a la vez.

```

class clase_1():
    (...)
class clase_2(clase_1):
    (...)
class clase_3(clase_2):
    (...)

class clase_4():
    (...)
class clase_5():
    (...)
class clase_6(clase_4, clase_5):
    (...)

```

Si existe una superposición de métodos llamados de la misma forma, la incongruencia se soluciona por el MRO (Method Resolution Order), el cual dicta que un método se resolverá primero según la clase actual, y si no, en la definición de las múltiples clases de izda. a dcha. o, si no, en niveles de herencia superiores.

En cuanto al polimorfismo, lo hemos visto ya indirectamente en Python, por ejemplo, en funciones que pueden admitir diferente número de argumentos o la longitud de los mismos.

El polimorfismo es la capacidad de utilizar un mismo nombre para referirse a procesos diferentes, puede aplicarse tanto a clases, como funciones y métodos, como variables. Lo cierto es que en Python el polimorfismo está definido implícitamente, aunque podemos verlo con algunos ejemplos:

```

print(len("hola"))
print(len([1, 2, 3]))

```

En este caso la función `len()` actúa polimórficamente sobre dos tipos de objetos de datos diferentes, un string y una lista.

Podemos verlo también:

```
class apple():
    def color():
        print("Red")
class pear():
    def color():
        print("Green")

def show_color(obj):
    obj.color()

obj_apple = apple()
obj_pear = pear()

show_color(obj_apple)
show_color(obj_pear)
```

d. Atributos públicos, protegidos y privados

Un atributo es público si es accesible desde fuera de la clase y no solamente desde sus métodos internos. Por ejemplo:

```
class persona():
    def saludo(self):
        print("Hola")

paco = persona()
paco.saludo()
```

Podemos acceder al método `saludo()` del objeto "paco" llamándolo directamente como `paco.saludo()`. Esto es lo que se conoce como **atributo público**, aquel que puede ser accedido desde cualquier parte dentro y fuera de la clase.

Por otro lado, si queremos que, por seguridad o privacidad, ciertos métodos y propiedades no sean accesibles directamente, podemos declararlos como protegidos o privados.

Un **atributo privado** es aquel que solamente puede ser accedido desde la propia clase en la que está definido. Por ejemplo:

```
class persona():
    def __init__(self, nombre):
        self.__nombre = nombre
```

```
paco = persona("Paco")
print(paco.__nombre) # Dará ERROR
```

Ahora, si intentamos acceder al atributo privado `__nombre` directamente, obtendremos un error. Habremos de acceder a él indirectamente por medio de un método público, por ejemplo:

```
class persona():
    def __init__(self, nombre):
        self.__nombre = nombre
    def mostrar_nombre(self):
        return self.__nombre

paco = persona("Paco")
print(paco.mostrar_nombre()) # Esto sí funcionará
```

Los atributos privados heredados de una clase superior deben ser accedidos a su vez llamando a algún método que devuelva su valor desde la clase padre.

```
class persona():
    def __init__(self, nombre):
        self.__nombre = nombre
    def mostrar_nombre(self):
        return self.__nombre

class estudiante(persona):
    def __init__(self, nombre):
        super().__init__(nombre)
    def mostrar_nombre_estudiante(self):
        return super().mostrar_nombre()
    # NO PODEMOS hacer:
    # return self.__nombre
```

```
paco = estudiante("Paco")

# Al ser ambas métodos públicos ambas funcionarán
print(paco.mostrar_nombre())
print(paco.mostrar_nombre_estudiante())
```

Si queremos que un atributo sea accedido desde las clases heredadas, podemos declararlo como atributo protegido.

```
class persona():
    def __init__(self, nombre):
        self._nombre = nombre
    def mostrar_nombre(self):
```

```

        return self._nombre

class estudiante(persona):
    def __init__(self, nombre):
        super().__init__(nombre)
    def mostrar_nombre_estudiante(self):
        # Ahora accedemos directamente al atributo protegido
        return self._nombre

paco = estudiante("Paco")

# Al ser ambas métodos públicos ambas funcionarán
print(paco.mostrar_nombre())
print(paco.mostrar_nombre_estudiante())

```

En resumen:

tipo de atributo	sintaxis	acceso desde la clase	acceso desde sub-clases	acceso desde todas partes
público	nombre	Sí	Sí	Sí
protegido	_nombre	Sí	Sí	NO*
privado	__nombre	Sí	NO*	NO*

* El acceso se realiza por medio de métodos públicos de la clase y la subclase

7. Librerías y módulos

Una librería o módulo es un archivo o conjunto de archivos que contienen definiciones de funcionalidades (como clases o funciones) que pueden importarse a otros scripts o programas para ser utilizadas.

La principal utilidad de un módulo es la de poder utilizar lo que está definido en él en varios scripts diferentes, ahorrándonos así el tener que definirlos localmente en cada uno de ellos.

Por ejemplo, supongamos que definimos una función "funcion()" que va a ser utilizada en 3 scripts (Ejemplo1.py, Ejemplo2.py y Ejemplo3.py). Pues en lugar de definir funcion() en cada uno de ellos, podemos definirla en un script de python aparte (lo que será nuestra librería) e importar ese script al resto.

Así pues, tendremos en la librería (la cual llamamos libreria.py, por ejemplo) lo siguiente:

```

def funcion():
    (...) # implementacion
    return

```

Mientras que al principio de cada uno de los otros script importaremos la librería. Por ejemplo, en Ejemplo1.py:

```
from libreria import funcion

# Podemos llamar a funcion como si la hubiéramos definido aquí
funcion()
```

Hay varias formas de importar módulos, dependiendo además de si queremos importarlos por completo o solo algunas partes.

Si queremos importar el módulo completo podemos hacerlo de dos formas:

```
import libreria

# Aquí tendremos que tratar las funciones del módulo como métodos de
la clase libreria
libreria.funcion()
```

O bien:

```
# El asterisco representa que importamos todo lo que haya en la
librería
from libreria import *

# Llamamos a la función como si la hubiéramos definido aquí
funcion()
```

Pero si solo queremos importar una función podemos hacer lo siguiente

```
from libreria import funcion

funcion()
```

También podemos cambiarle el nombre a dicha función, muy útil si en varias librerías hay funciones con el mismo nombre pero diferente implementación.

```
from libreria import funcion as nuevo_nombre

nuevo_nombre() # Ejecutará funcion(), pero se llama nuevo_nombre
```

Siguiendo con esta lógica podemos importar varias funciones concretas, ya sea en una línea o varias:

```
from libreria import funcion1, funcion2
from libreria import funcion3
```

importar el módulo como una clase	<code>import module_name</code>
importar todas las funciones y clases	<code>from module_name import *</code>
importar solo una función o clase	<code>from module_name import x</code>
importar solo una función o clase y cambiarle el nombre	<code>from module_name import x as new_name</code>
importar funciones o clases concretas	<code>from module_name import x, y, z</code> <code>from module_name import a</code> <code>from module_name import b</code> <code>from module_name import c</code>

Ejemplo práctico con el módulo `numpy`:

```
import numpy
vector = numpy.array([...])
```

```
import numpy as np
vector = np.array([...])
```

```
from numpy import array
vector = array([...])
```

Por otro lado, un **paquete** o **package** es una carpeta en la cual guardamos diversos módulos. Esto se hace por organización dentro de una aplicación.

Si el script de nuestra aplicación se encuentra en su directorio (al cual nos referiremos por su path relativo), un paquete sería una carpeta en el mismo directorio en el cual se guardan los módulos. Si dicha carpeta (`./pck/`) contiene dos módulos (`mod1.py` y `mod2.py`) podemos acceder a ellos de la siguiente forma:

```
import pck.mod1
from pck.mod2 import funcion
```

Lo trataremos de la misma forma que si fuese un módulo. Pudiendo hacer lo siguiente:

```
import package_name
from package_name import module1
from package_name.module1 import x
```

Las librerías o módulos que podemos usar en Python son muchas y además existen multitud de módulos que podemos instalar con facilidad por medio de **pip** o **conda**.

Para instalar un módulo en nuestra shell de python, podemos abrir una terminal del sistema operativo (o una terminal de Anaconda) para hacer lo siguiente:

```
pip install module_name
```

Para una versión concreta:

```
pip install module_name==version
```

Si queremos ver los módulos instalados:

```
pip list
```

Y si tenemos dudas con los comandos:

```
pip --help
pip -h
pip command_name --help
```

finalmente para desinstalar un paquete:

```
pip uninstall module_name
```

Por otro lado, para Anaconda, podemos ver los comandos aquí:

https://docs.conda.io/projects/conda/en/4.6.0/_downloads/52a95608c49671267e40c689e0bc00ca/conda-cheatsheet.pdf

Si queremos instalar las dependencias e un repositorio de Github, podemos hacerlo con pip

```
pip install git+https://bitbucket.org/<project_owner>/<project_name>
pip install git+ssh://git@bitbucket.org/<project_owner>/<project_name>.git/
```

8. Decoradores

Un decorador es una forma simple de extender las funcionalidades de una función. En sí, un decorador no es más que una función a la que se le pasa otra función como argumento, pero que tiene una sintaxis propia en Python.

```
function = decorator(function) # Sintaxis tradicional

# Sintaxis en python
@decorator
def function(...):
    ...
```



```
function()
```

Tanto las funciones como los métodos de una clase son elementos considerados “llamables”, es decir, que se les puede llamar para su ejecución desde otra parte del código. Al ser llamables, ambos contienen el método `__call__()`, de esta forma, podemos definir un decorador como una función que devuelve un elemento al que se le puede llamar, esto es, otra función.

La estructura común de un decorador es la siguiente, se define el decorador, al cual se le pasa el nombre de una función, dentro del mismo se define otra función, normalmente llamada “wrapper”, de argumentos genéricos, en el cual se hace la ampliación de funcionalidad de la función que se ha decorado y finalmente se devuelve :

```
def decorador(func):
    def wrap_func(*args, **kwargs):
        (...)
        return func(*args, **kwargs)
    return wrap_func

@decorador
def funcion_de_ejemplo(...):
    (...)

funcion_de_ejemplo()
```

Así pues, hemos decorado `funcion_de_ejemplo`, de forma que el namespace de esta función se pasará como un argumento al decorador, que a su vez pasará los argumentos de dicha función a la función de wrapper, `wrap_func`, que trabajará con ellos si es necesario, devolviendo la función `funcion_de_ejemplo` con sus argumentos y, finalmente, el decorador devolverá `wrap_func`.

En realidad, los decoradores no son, si no, llamadas a una función que añade una funcionalidad a otra sin modificar la misma. De una forma más tradicional podríamos llamar al decorador de la siguiente forma:

```
nombre = decorador(funcion_de_ejemplo )
nombre()
```

Y esto ejecutaría el código de la misma forma.

Podemos, además, encadenar varios decoradores. Los cuales se ejecutarán de arriba a abajo:

```
def decorador1(func):
    def wrapper(*args, **kwargs):
```

```

        print("Decorador 1")
        return func(*args, **kwargs)
    return wrapper

def decorador2(func):
    def wrapper(*args, **kwargs):
        print("Decorador 2")
        return func(*args, **kwargs)
    return wrapper

@decorador1
@decorador2
def funcion(x):
    print(f"{x} ** 2 = {x**2}")

funcion(5)

```

Haciendo esto, obtendremos por pantalla lo siguiente:

```

Decorador 1
Decorador 2
5 ** 2 = 25

```

Por último, si queremos decorar un decorador, tendremos realmente que decorar la función wrapper del decorador de la siguiente forma:

```

def decorador1(func):
    def wrapper(*args, **kwargs):
        print("Decorador 1")
        return func(*args, **kwargs)
    return wrapper

def decorador2(func):
    @decorador1
    def wrapper(*args, **kwargs):
        print("Decorador 2")
        return func(*args, **kwargs)
    return wrapper

```

9. Tratamiento de excepciones y el try/except

En Python tenemos muchas excepciones que van desde simples advertencias (o warnings) a errores fatales. Si queremos manejar dichas excepciones para evitar la interrupción de la ejecución del programa, o para poder controlar mejor nuestro código, podemos hacer uso de la sentencia **try/except**:

```
try:
    (...) # intentamos ejecutar este bloque de código
except:
    (...) # si el try no funciona, hacemos esto
```

Pero qué pasa si queremos que una parte del código se ejecute sí o sí. Para ellos podemos hacer uso de **finally**:

```
try:
    (...) # intentamos ejecutar este bloque de código
except:
    (...) # si el try no funciona, hacemos esto
finally:
    (...) # esta parte siempre se ejecuta
```

Si en el bloque del try no ha saltado ninguna excepción podemos hacer uso del **else**:

```
try:
    (...) # intentamos ejecutar este bloque de código
except:
    (...) # si el try no funciona, hacemos esto
else:
    (...) # si no ha habido excepciones en el try, hacemos esto
finally:
    (...) # esta parte siempre se ejecuta
```

Para poder visualizar la excepción concreta que ha saltado, podemos modificar la parte del except de esta forma:

```
except Exception as e:
    (...)
    print(e)
    (...)
```

A su vez, un try/except puede hacer uso de varios except.

Finalmente, para obligar a hacer que salte una excepción, podemos hacer uso de la palabra reservada **raise**

```
raise exception_name
```

Podemos ver las excepciones de Python aquí:

<https://docs.python.org/3/tutorial/errors.html>

10. Los módulos NumPy, Matplotlib y Pandas

a. Matplotlib

Matplotlib es una librería de plotado de gráficos bastante generalista. Suele utilizarse junto con la librería NumPy por la compatibilidad con los arrays de la misma, aunque no es necesario.

Podemos importar la librería entera, aunque a veces solo necesitamos el módulo de plotado.

```
import matplotlib # Podemos importar todo el módulo
import matplotlib.pyplot as plt # o solo el plotado
```


Supongamos ahora que queremos dibujar un gráfico que represente una línea recta, pues podemos hacerlo de la siguiente forma:

```
import matplotlib.pyplot as plt
import numpy as np

x_values = np.array([0, 5])
y_values = np.array([1, 7])

plt.plot(x_values, y_values)
plt.show()
```


El gráfico que se nos abriría en una ventana sería:



El gráfico representa un segmento que empieza en el punto (0, 1) y termina en el punto (5, 7).

Podemos hacer que se resalten dichos puntos añadiendo el parámetro `marker = 'o'` en la creación del plot:

```
plt.plot(x_values, y_values, marker = 'o')
```



También podemos darle la opción `linestyle = 'dotted'` para hacer que la línea sea de puntos, o `linestyle = 'dashed'` para que sea discontinua.

tipo de línea	formato completo	formato abreviado
sólida	<code>linestyle = 'solid'</code>	<code>ls = '-'</code>
de puntos	<code>linestyle = 'dotted'</code>	<code>ls = ':'</code>
discontinua	<code>linestyle = 'dashed'</code>	<code>ls = '--'</code>
punto - raya	<code>linestyle = 'dashdot'</code>	<code>ls = '-.'</code>
sin línea	<code>linestyle = 'None'</code>	<code>ls = ''</code> or <code>ls = ' '</code>

También podemos darle una opción de color, parándole colores predeterminados (como 'r' para rojo) o su valor RGB en hexadecimal. El parámetro en cuestión será `color` o, simplemente, `c`.

```
plt.plot(x_values, y_values, color = 'r')
plt.plot(x_values, y_values, c = '#004A5B')
```

También podemos acceder al ancho de la línea con el parámetro `linewidth` o `lw`, al cual hay que pasarle el ancho en un string que represente el número en puntos:


```
plt.plot(x_values, y_values, linewidth = '10')
plt.plot(x_values, y_values, lw = '3.2')
```

Si a la creación del gráfico solo le pasamos los valores de la coordenada Y, supondrá que los puntos se encuentran en $x = 0$, $x = 1$, $x = 2$ y así sucesivamente.

```
import matplotlib.pyplot as plt
import numpy as np

y_values = np.array([1, 7, 5, 3, 1, 0, 4])

plt.plot(y_values, marker = 'o')
plt.show()
```




Para representar un gráfico sobre otro, llamamos seguidamente a `plt.plot()` con cada serie de datos antes de mostrarlos con `plt.show()`.

```
import matplotlib.pyplot as plt
import numpy as np

y_1 = np.array([1, 7, 5, 3, 1, 0, 4])
y_2 = np.array([3, 5, 2, 0, 4, 0, 6])

plt.plot(y_1 , color = 'b')
plt.plot(y_2 , color = 'y')
plt.show()
```



También podríamos haberlo hecho pasándole los términos de las x y las y a un solo plot.

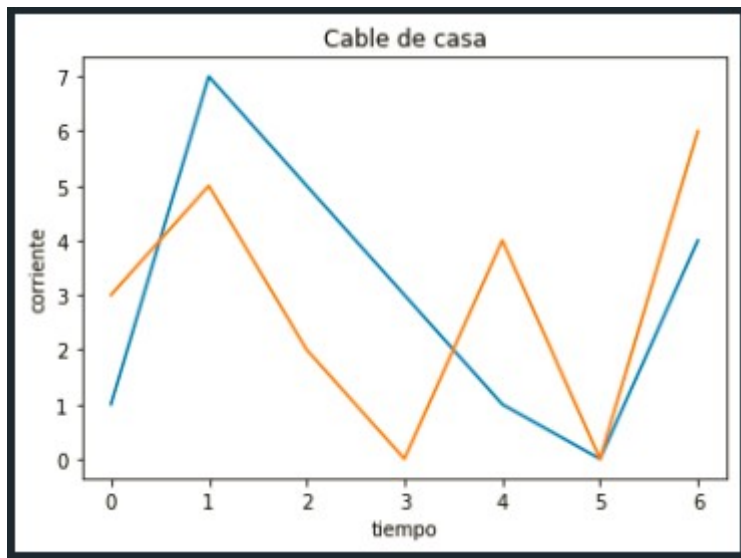
```
import matplotlib.pyplot as plt
import numpy as np

y_1 = np.array([1, 7, 5, 3, 1, 0, 4])
x_1 = np.array([0, 1, 2, 3, 4, 5, 6])
y_2 = np.array([3, 5, 2, 0, 4, 0, 6])
x_2 = np.array([0, 1, 2, 3, 4, 5, 6])

plt.plot(x_1, y_1, x_2, y_2)
plt.show()
```

Ahora que ya sabemos generar gráficos, nos damos cuenta de que, sin embargo, éstos no dan información de lo que se representa, para ello existen las opciones xlabel e ylabel. También podemos añadir un título.

```
plt.plot(x_1, y_1, x_2, y_2)
plt.title("Cable de casa")
plt.xlabel("tiempo")
plt.ylabel("corriente")
plt.show()
```



Podemos a su vez añadir una cuadrícula si nos resulta útil:

```
plt.grid() # cuadrícula
plt.grid(axis = 'x') # solo líneas verticales
plt.grid(axis = 'y') # solo líneas horizontales
```

Para dibujar varias gráficas separadas en un mismo plot utilizamos el método `plt.subplot()`, cuyos argumentos son:


```
plt.subplot(N_filas, N_columnas, posicion_de_esto_plot)
```

Por ejemplo:

```
y_1 = np.array([1, 7, 5, 3, 1, 0, 4])
y_2 = np.array([3, 5, 2, 0, 4, 0, 6])

plt.subplot(2, 1, 1) # 2 filas, 1 columna y primera posicion
plt.plot(y_1 , color = 'b')


plt.subplot(2, 1, 2) # 2 filas, 1 columna y segunda posicion
plt.plot(y_2 , color = 'y')
plt.show()
```

Si en lugar de hacer una línea de puntos queremos hacer un gráfico de puntos, utilizamos el método `scatter()`:

```
y_1 = np.array([1, 7, 5, 3, 1, 0, 4])
x_1 = np.array([0, 1, 2, 3, 4, 5, 6])

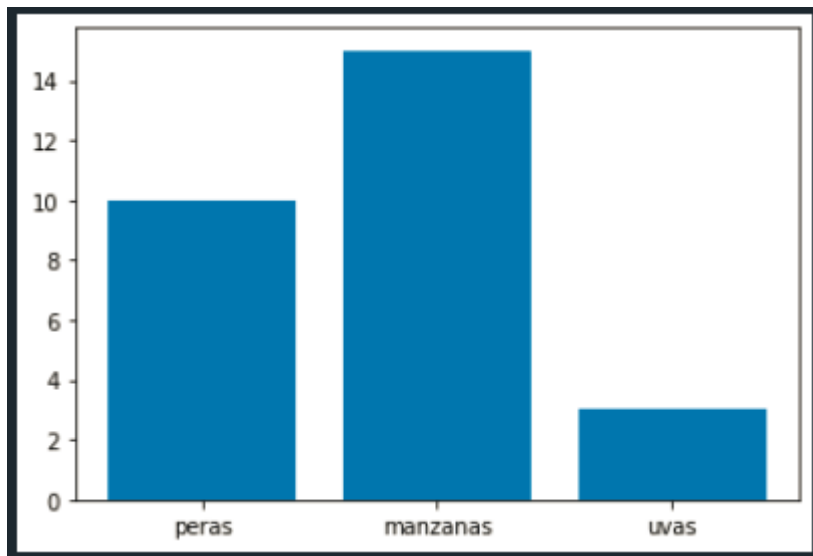
plt.scatter(x_1, y_1)
plt.show()
```



Para hacer gráficos de barras usamos el método `bar()`

```
y = [10, 15, 3]
x = ['peras', 'manzanas', 'uvas']


plt.bar(x, y)
plt.show()
```



Si las barras las queremos horizontales, usaremos el método `barh()`

Para hacer histogramas también tenemos el método `hist()`. Si queremos, por ejemplo, hacer el histograma de una distribución normal, podríamos hacerlo de la siguiente forma:

```
# Creamos un array en una distribución normal centrada en 50,  
# con desviación estándar de 10 y  
# 500 elementos  
x = np.random.normal(50, 10, 500)  
plt.hist(x)  
plt.show()
```



b. NumPy

NumPy es un módulo de Python que trata sobre todos con datos similares a las listas, pero de forma mucho más rápida y eficiente, debido a que los datos de numpy se acumulan de forma continua en memoria.

Para importar el módulo, como siempre:

```
pip install numpy
```

Para importar el módulo, es común llamarlo np:

```
import numpy
import numpy as np
```

NumPy trabaja con un tipo de dato propio llamado ndarray, que se crea con el método `array()` y es similar a las listas. Este método también sirve para convertir tipos de datos como listas, tuplas, o cualquier otro que sea similar a ndarray.

```
import numpy as np

arr = np.array([2, 4, 5,...])
```

Debemos ahora hablar de las dimensiones de los arrays. Un array puede tener de 0 a N dimensiones. La forma más común de referirse a ellos según las dimensiones es:

Dim.	Nombre	Forma
0	escalar (número)	<code>np.array(42)</code>
1	array o vector	<code>np.array([1, 2, 3])</code>
2	matriz (o matriz bidimensional)	<code>np.array([[1, 2, 3], [4, 5, 6]])</code>
3	matriz tridimensional	<code>np.array([[[...], [...], ...], [...], [...], ...], ...])</code>
4 o más	tensor o matriz de N dimensiones	

Podemos ver que realmente se pueden traducir los arrays multidimensionales como arrays de arrays de arrays hasta llegar a números. Así por ejemplo, una matriz bidimensional sería un array de array de números.

Además de convertir listas, podemos crear nuestros propios vectores:

```
arr_zeros = np.zeros(10) # array 1D de 10 ceros
mat_zeros = np.zeros((10,10)) # matriz de 10x10 de ceros
```

```
arr = np.array(range(10, 50)) # vector que contiene números del 10 al 49
```

```
arr_rand = np.random.random(10) # array de 10 números aleatorios  
mat_rand = np.random.random((3, 3, 3)) # matriz tridimensional de num aleatorios
```

Para hacer un array con elementos dentro de una distribución normal, usamos `random.normal()`, a la que se le pasan la media, la desviación típica y el número de elementos que queremos, respectivamente.

```
arr_normal = np.random.normal(10, 5, 400)
```

También podemos conocer las dimensiones del array y cambiarlas:

```
arr = np.array(...)  
print(arr.shape) # muestra las dimensiones  
  
new_shape = (3, 3) # int o tupla de ints  
np.reshape(arr, new_shape) # Cambio de dimensiones usando una función  
arr = arr.resize(new_size) # cambio de dimensiones usando un método de la clase array
```

Podemos encontrar un compendio de los comandos más utilizados aquí:

https://assets.datacamp.com/blog_assets/Numpy_Python_Cheat_Sheet.pdf

c. Pandas

Para realizar las operaciones matemáticas propias del Machine Learning existen multitud de módulos y librerías más óptimos que el código básico del lenguaje, este es el caso para Numpy y Pandas.

Pandas es una herramienta de análisis de datos

11. Tratamiento de imágenes y PDF

a. Módulos os, sys y shutil

Aunque ya hemos visto cómo abrir, leer y editar archivos, es, a su vez, importante conocer la forma de poder comunicarse con el sistema operativo desde un script.

El módulo **os** permite utilizar funcionalidades propias del sistema operativo, mientras que su parte **os.path** ayuda de forma sencilla a trabajar con directorios.

El módulo **sys** permite trabajar con el intérprete de Python y con sus variables desde dentro de un script.

El módulo **shutil** provee funcionalidades de alto nivel para el trabajo con archivos y colecciones de archivos.

Se puede visitar la documentación de estos tres módulos aquí:

Módulo os	Módulo sys	Módulo shutil
---------------------------	----------------------------	-------------------------------

Cuando trabajamos con direcciones de archivos y carpetas, esto es, **paths**, debemos tener cuidado con su formato, sobre todo si trabajamos en Windows, pues el caracter especial de separación en un path es la **backslash** “\”, la cual tiene otras utilidades dentro de una string.

Pudiera darse el caso, por ejemplo, de que copiemos directamente un path desde el explorador de Windows y lo copiemos en una variable string:

```
path = 'C:\path\to\directory'
```

Entonces el intérprete de python nos diría que hemos cometido un error. Para solventar dicho error hay dos formas de hacerlo. Si el path no acaba en “\”, podemos transformar la cadena de caracteres en una string raw, que interpreta todos literalmente, poniendo una “r” antes de abrir comillas. Por otro lado, tanto si el path termina en “\” como si no, siempre podemos sustituir las backslash simples por backslash doble, que Python interpretará entonces como el caracter “\”.

```
path = r'C:\path\to\directory'
path = 'C:\\path\\to\\directory'
```

Veamos una serie de ejemplos simples para trabajar con estos módulos.

Si queremos saber desde qué directorio estamos trabajando y cambiar dicho, podemos hacer:

```
os.getcwd()      # para saber el directorio actual
os.chdir(path)   # para cambiar el directorio a path
```

Pero cómo asegurarnos de que un directorio o un archivo existen, pues para ello el módulo **os.path** nos proporciona las funciones:

```
os.path.exists(path) # Devuelve True si existe el archivo o
directorio
os.path.isdir(path_to_dir) # Devuelve True si existe y es un
directorio
```

```
os.path.isfile(path_to_file) # Devuelve True si existe y es un
archivo
```

También podemos crear directorios:

```
os.mkdir(path)
```

Y ver qué tienen en su interior:

```
os.listdir(path)
```

Por otro lado, `shutil` nos proporciona multitud de herramientas de manejo de archivos y directorios. Con él podemos, por ejemplo, borrar un directorio y todos sus contenidos, moverlos o copiarlos:

```
shutil.rmtree(path) # borra todos los contenidos de una carpeta
shutil.copytree(source_path, dest_path) # copia una carpeta
shutil.move(source_path, dest_path) # mueve una carpeta
shutil.copy(source_file, dest_path) # copia un archivo
```

También podemos comprimir una carpeta y sus contenidos:

```
shutil.make_archive(file_to_create, extension, root_dir, base_dir)
```

Donde:

- `file_to_create`: path al archivo a crear, sin la extensión
- `extesion`: extensión del archivo
- `root_dir`: directorio base del archivo, por defecto el actual. Es lo que se quiere comprimir
- `base_dir`: desde donde se empieza a comprimir, por defecto el directorio actual. Si el comando trabaja desde `root_dir` (y hace de este el directorio base del archivo) `base_dir` es la carpeta dentro de `root_dir` que comprimiaremos.

```
shutil.make_archive('nombre', 'zip', 'carpeta/a/comprimir',
'subcarpeta/base/del/zip')
```

b. PIL e imágenes en Python

PIL es el módulo que instalamos con el paquete Pillow:

```
pip install Pillow
```

Con este módulo podemos abrir, modificar y guardar imágenes. Para abrir y cerrar el archivo lo tratamos como cualquier otro archivo:

```
from PIL import Image
```

```
img = Image.open(filename)
(...)
img.close()
```

```
with Image.open(filename) as img:
    (...)
```

NOTA: en una imagen de PIL las coordenadas tienen su origen en la esquina superior izda.

Algunas de las funciones más comunes de la librería pueden ser:

Uso del método	Método o atributo	Explicación
Procesado de imágenes	<code>alpha_composite(im1, im2)</code>	hace un compositado alfa de img2 sobre img1, devolviendo una imagen
	<code>blend(im1, im2, alpha)</code>	
	<code>composite(image1, image2, mask)</code>	
	<code>merge(mode, bands)</code>	
Creación	<code>new(mode, size, color=0)</code>	crea una nueva imagen
	<code>fromarray(obj, mode=None)</code>	conversión a través de un array de numpy
Efectos sobre la imagen	<code>effect_mandelbrot(size, extent, quality)</code>	
	<code>effect_noise(size, sigma)</code>	
	<code>linear_gradient(mode)</code>	
	<code>radial_gradient(mode)</code>	
Métodos de la clase Image (PIL.Image.Image)	<code>Image.alpha_composite(im, dest=(0, 0), source=(0, 0))</code>	Compone una imagen (im) sobre nuestra imagen
	<code>Image.apply_transparency()</code>	Aplica transparencia a la paleta de la imagen
	<code>Image.copy()</code>	
	<code>Image.crop(box=None)</code>	corta la imagen, box es una tupla de coordenadas de 4 elementos: (izda., arriba, dcha., abajo)
	<code>Image.paste(im, box=None, mask=None)</code>	Pega una imagen sobre nuestra imagen. box puede ser una tupla (izda., arriba) o (izda., arriba, dcha., abajo) y es donde se pega im
	<code>Image.resize(size, resample=None, box=None, reducing_gap=None)</code>	redimensiona la imagen, donde size es una tupla (width, height)
	<code>Image.rotate(angle, resample=Resampling.NEAREST, expand=0, center=None,</code>	rota la imagen en sentido antihorario, con un ángulo dado en grados sexagesimales

	<i>translate=None, fillcolor=None)</i>	
	<i>Image.save(fp, format=None, **params)</i>	guarda la imagen, donde fp es el nombre del archivo y format la extensión ('PNG', 'JPEG',...)
	<i>Image.show(title=None)</i>	muestra la imagen
	<i>Image.transpose(method)</i>	gira la imagen 90°
	<i>Image.close()</i>	cierra la imagen
Atributos de la clase Image	Image.filename: str	nombre del archivo
	Image.format: optional str	formato de la imagen
	Image.width: int	ancho en píxeles
	Image.height: int	alto en píxeles
	Image.palette: optional PIL.ImagePalette.ImagePalette	
	Image.info: dict	
	Image.is_animated: bool	
	Image.n_frames: int	

Además de Image, PIL contiene otros módulos, como ImageDraw, que sirve para dibujar en una imagen.

La documentación del módulo PIL la podemos encontrar aquí:

<https://pillow.readthedocs.io/en/stable/reference/index.html>

c. Trabajando con PDF

Un archivo .pdf, por sus siglas “Portable Document Format”, es un archivo de texto e imagen creado por Adobe, aunque ahora es administrado por la ISO (“International Organization for Standardization”).

Para trabajar con pdfs en Python existe una plétora de módulos, aunque los más comunes son PyPDF2 y PyPDF3, que derivan de otro módulo más antiguo, PyPDF. En general, PyPDF2 es la más utilizada en la documentación disponible, siendo PyPDF3 la más moderna. Además, tenemos el módulo PyFPDF, especializado en la generación de pdfs a través de Python.

```
pip install pypdf2
pip install pypdf3
pip install fpdf
```


Usando PyPDF2 podemos, por ejemplo, leer el contenido de un pdf:

```
import PyPDF2

pdf = open(filename, 'rb')
pdf_reader = PyPDF2.PdfReader(pdf)

for i in range(pdf_reader.numPages):
    page = pdf_reader.getPage(i)
    print(page.extractText())

pdf.close()
```

Un objeto PyPDF2.PdfFileReader puede darnos información el archivo:

```
print(pdf_reader.numPages)
print(pdf_reader.documentInfo)
```

Para escribir un nuevo archivo, podemos:

```
pdf_writer = PyPDF2.PdfWriter()
(...)
pdf_writer.addPage(pageObj)
(...)
new_pdf = open(newfile, 'wb')
pdf_writer.write(new_pdf)
new_pdf.close()
```

Aunque también podemos hacer uso de las funcionalidades de FPDF:

```
from fpdf import FPDF

pag_orientation = 'P' # P: portrait(vertical)      L:
landscape(horizontal)
pag_format = 'A4' # NOTA: fpdf da las dimensiones en mm

pdf = FPDF(orientation = pag_orientation, unit = 'mm', format =
pag_format)

pdf.add_page()
pdf.set_font("Arial", size=12) # font and textsize
pdf.cell(200, 10, txt="your text", ln=1, align="L")
pdf.output(path_pdf, "F")
```

Podemos ver todas las funcionalidades de FPDF aquí:

<https://pyfpdf.readthedocs.io/en/latest/index.html>

12. Bases de datos MongoDB

Una base de datos es una recopilación organizada de información o de datos estructurados, controlada por un sistema de gestión de bases de datos.

MongoDB es una base de datos que, a diferencia de otras más comunes, como SQL, organiza sus datos en formato de archivos json, organizados en colecciones de documentos. Una base de datos de MongoDB puede tener varias colecciones.

Los archivos json (JavaScript Object Notation) son fácilmente interpretables gracias a su módulo homónimo. Así pues, se proporciona una traducción directa de los tipo de dato:

json	python	json	python
object	dict	number(real)	float
array	list	true	True
string	str	false	False
number(int)	int	null	None

Aunque dicho módulo es extenso, sus dos principales funciones son las de crear y leer un json, utilizando **json.dumps()** y **json.loads()** respectivamente.

```
import json

dict_example = {'name': 'José', 'age': 45}

# pasamos el diccionario a json
json_example = json.dumps(dict_example)

# pasamos el json a diccionario
dict_decoded = json.loads(json_example )
```

Por supuesto, ambas funciones tienen muchos más argumentos, tal y como se ve en su definición:

```
json.dumps(obj, *, skipkeys=False, ensure_ascii=True,
check_circular=True, allow_nan=True, cls=None, indent=None,
separators=None, default=None, sort_keys=False, **kw)

json.loads(s, *, cls=None, object_hook=None, parse_float=None,
parse_int=None, parse_constant=None, object_pairs_hook=None, **kw)
```

También existen las funciones `json.load()` y `json.dump()`, pero estas leen un json para convertirlo en un “file-like object” o viceversa, en lugar de a un tipo de dato str, bytes o bytearray.

Lo primero, como siempre, es instalar las librerías. En ambos casos puede utilizarse pip:

```
pip install pymongo
pip install json
```

Una vez hecho esto, podemos empezar a trabajar con MongoDB.

Lo primero, es crear en nuestro código un cliente que nos permita acceder a la base de datos. Podemos hacer que este cliente se conecte al host y el port por defecto, podemos especificarlo o podemos conectarnos a través de una url.

```
from pymongo import MongoClient

client = MongoClient()
client = MongoClient('localhost', 27017)
client = MongoClient('mongodb://localhost:27017/')
```

Ahora podemos acceder a nuestra base de datos, lo cual podemos hacer de las siguientes formas:

```
mydb = client.my_database
mydb = client['my-database']
```

Dentro de nuestra base de datos, podemos acceder a sus colecciones de forma similar:

```
mycol= mydb.my_collection
mycol= mydb['my-collection']
```

Cuidado en ambas notaciones con la diferencia entre guión (“-”) y la barra baja (“_”).

Ahora ya estamos listos para realizar operaciones con los json de nuestra base de datos.

Método	Explicación
mycol.find({"hello": "world"})	Busca todos los documentos que cumplan con el filtro especificado. Si ese filtro se deja vacío ({}), buscará todos los elementos.
mycol.find_one(search_json = my_search_json)	Busca un json en la base de datos
mycol.find_one_and_update(search_json = my_search_json, new_json = my_new_json)	Busca un json y lo cambia por uno nuevo
mycol.insert_one(new_json = my_new_json)	Inserta un nuevo json en la colección
mycol.insert_many(array_jsons = my_array_jsons)	Inserta todos los elemento de una lista de json en la colección
mycol.update_one(search_json =	Cambia un json en la colección por uno nuevo:

<code>my_search_json, changes_json = my_changes_json)</code>	
<code>mycol.remove({filter_dict})</code>	<p>Elimina todos los elementos que concuerden con el filtro.</p> <p>CUIDADO: los datos eliminados no se pueden recuperar.</p>

Un ejemplo de `update_one()`:

```
client = MongoClient()
mydb = client['my-database']
mycol= mydb['my-collection']

search_json = {"key1": value1, "key2": value2}
update_q = {"$set": {"key_to_update": value_to_update}}
mycol.update_one(search_json, update_q)
```

Existen, además, diferentes operadores de MongoDB, cuya sintaxis es siempre “\$<operador>”, como el \$set de la operación de `update_one()`. Otros operadores de interés pueden ser:

operador	definición	ejemplo
‘\$set’	actualiza o añade un campo	
‘\$unset’	borra un campo	
‘\$rename’	renombrar un campo	

13. Matemáticas aplicadas a la Inteligencia Artificial

La Inteligencia Artificial surgió a partir del estudio de las capacidades de los seres biológicos de resolver problemas y aprender a raíz de las soluciones obtenidas. Pero para realizar dichos estudios es necesario hacer uso de un planteamiento formal del modelo que emula el pensamiento como de su capacidad de aprendizaje. Para ello nos apoyamos en varias ramas de las matemáticas.

Utilizamos el álgebra lineal para, por ejemplo, plantear los modelos de inteligencia artificial y las conexiones entre sus elementos.

El cálculo nos sirve para analizar y controlar el aprendizaje de nuestra inteligencia artificial.

La estadística nos ayuda a interpretar los resultados obtenidos, así como a hacer predicciones e identificar patrones.

a. Álgebra lineal

El álgebra lineal se encarga del estudio de los campos vectoriales, vectores, matrices y transformaciones lineales, es decir de ecuaciones de la forma:


$$a_1 \cdot x_1 + a_2 \cdot x_2 + \dots + a_n \cdot x_n = c$$

Los elementos algebraicos que a nosotros más nos interesan son los vectores, las matrices y los tensores.

Un vector representa una cantidad con una magnitud y una dirección en el espacio que lo contiene. formalmente podemos definirlo como un elemento que contiene una tupla de tantos elementos como dimensiones haya en el espacio vectorial que lo contiene.

$$v = (x_1, x_2, \dots, x_n) \text{ donde } v \in \mathbb{R}^n$$

Si representamos los vectores en un espacio bidimensional o tridimensional, podemos ver que estos representan la distancia entre los puntos del espacio.



En un espacio de n dimensiones, los puntos de dicho espacio se pueden representar como el vector que va desde el origen del sistema de coordenadas hasta las coordenadas del punto en cuestión. La distancia del origen al punto en cuestión sería el módulo del vector.

Hemos visto que un vector puede definirse a partir de la dirección que sigue, el sentido que tiene en esa dirección y su módulo, es decir, lo “grande” o “pequeño” que es. Podemos calcular el módulo de un vector como:

Sea v un vector tridimensional: $v = (x, y, z)$

$$|v| = \sqrt{x^2 + y^2 + z^2}$$

Además podemos sumar y restar vectores. Esta operación se realiza término a término.


$$v = (v_x, v_y, v_z)$$

$$u = (u_x, u_y, u_z)$$

$$u + v = (u_x + v_x, u_y + v_y, u_z + v_z)$$

$$u - v = (u_x - v_x, u_y - v_y, u_z - v_z)$$

Gráficamente, podemos ver que la suma o la resta de vectores representan las diagonales mayor y menor del paralelogramo construido por u y v, respectivamente.



La multiplicación de vectores puede resultar más compleja y depende de los operandos y el operador.

- Un vector por un escalar da otro vector cuyos elementos estén multiplicados por dicho escalar, así como su módulo.

$$b * v = b * (v_x, v_y, v_z) = (b * v_x, b * v_y, b * v_z)$$

$$\hat{i} b * v \vee \hat{i} b * \hat{i} v \vee \hat{i}$$


- Un vector por otro vector normalmente se refiere al producto escalar y da como resultado otro número escalar.

$$u * v = \hat{i} u_x * v_x + u_y * v_y + u_z * v_z$$

De este producto escalar se puede hallar el ángulo que forman los vectores:

$$u * v = \hat{i} u \vee \hat{i} v \vee \hat{i} \cos(\theta)$$

Donde theta (θ) es el ángulo entre los vectores.



- Para vectores tridimensionales, el producto vectorial o producto por menores da el vector perpendicular a ambos, siguiendo la regla de la mano derecha.

$$\vec{u} \times \vec{v} = \begin{vmatrix} \vec{i} & \vec{j} & \vec{k} \\ u_x & u_y & u_z \\ v_x & v_y & v_z \end{vmatrix} = (u_y \cdot v_z - v_y \cdot u_z, v_x \cdot u_z - u_x \cdot v_z, u_x \cdot v_y - v_x \cdot u_y)$$

En este caso se conocería al vector resultante como el vector u sobre v. Además se cumpliría que:

$$\vec{u} \times \vec{v} = -\vec{v} \times \vec{u} \quad \text{Conocida como la regla de la anticonmutatividad.}$$

$$|\vec{u} \times \vec{v}| = |\vec{u}| \cdot |\vec{v}| \cdot \sin(\theta)$$

Nota: en matemáticas los vectores, realmente, siempre se representan en vertical (es decir, que tienen una columna y n filas), aunque, por simplicidad, aquí se representan por filas.

Cabe destacar un tipo de vectores muy especiales, los vectores unitarios, que son aquellos cuyo módulo vale 1. Podemos hallar el vector unitario de otro dividiendo a éste por su módulo.

$$\vec{u} = \frac{\vec{v}}{|\vec{v}|} \implies |\vec{u}| = 1$$

Las matrices son conjuntos bidimensionales de números que, en el contexto de un espacio vectorial, representan transformaciones lineales de los vectores de dicho campo. Si un vector estaba contenido en un espacio de n dimensiones, una matriz está contenida en un espacio de nxm dimensiones, donde n son las filas y m las columnas de la matriz

$$[A] = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{bmatrix} \text{ donde } [A] \in \mathbb{R}^{n \times m}$$

Hay muchos tipos de matrices, pero destacan:

- **Matrices cuadradas**, aquellas que tienen el mismo número de filas que de columnas
- **Matrices diagonales**, aquellas cuyos elementos distintos a cero se encuentran en la diagonal de la matriz. La diagonal es el conjunto de elementos de una matriz donde la i y la j son iguales.
- **Matriz identidad**: la matriz cuyos elementos son 0 excepto los de la diagonal, que son 1.

$$I = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

- **Matrices triangulares:**
 - Triangular superior: los elementos de la diagonal y por encima pueden ser distintos de 0.
 - Triangular inferior: los elementos de la diagonal y por debajo de la misma son distintos de 0.
- **Matriz traspuesta:** Es aquella en la que se intercambian los elementos de las filas y las columnas de otra matriz. Si la matriz original tenía dimensiones $n \times m$, la matriz traspuesta es de dimensiones $m \times n$.

$$[A] = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{bmatrix} \implies [A]^T = \begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{12} & a_{22} & a_{32} \end{bmatrix}$$

- **Matriz inversa:** es una matriz que satisface la condición:

$$[A] \cdot [A]^{-1} = I$$

La matriz inversa no siempre puede existir, ya que la matriz original debe cumplir ciertas condiciones. Una matriz que se puede invertir es una matriz regular o invertible, si no, es una matriz degenerada. Algunas de las condiciones que debe cumplir son:

- El determinante de la matriz es distinto de cero
- La matriz debe ser cuadrada
- **Submatriz:** matriz formada por elementos escogidos de otra más grande. Si una matriz tiene dietas filas y columnas de valor 0, puede utilizarse para simplificar operaciones, o para rellenar matrices en caso de que no coincidan las dimensiones.

Volviendo al tema anterior, hemos visto que la suma y resta de un vector da otro vector cuyos términos son la suma y resta de los elementos de los vectores. Para matrices pueden aplicarse las mismas reglas.

$$[A] + [B] = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} + \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix} = \begin{bmatrix} a_{11} + b_{11} & a_{12} + b_{12} \\ a_{21} + b_{21} & a_{22} + b_{22} \end{bmatrix}$$

así como el producto por un escalar:

$$b \cdot [A] = b \cdot \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} = \begin{bmatrix} b \cdot a_{11} & b \cdot a_{12} \\ b \cdot a_{21} & b \cdot a_{22} \end{bmatrix}$$

Sin embargo, es en el producto de matrices donde se complica la cosa. Para multiplicar dos matrices se debe cumplir que el las columnas de la primera coincidan con las columnas de la segunda.

$$[A]^{n \times m} \cdot [B]^{m \times p} = [C]^{n \times p}$$

Poniendo un ejemplo:

$$[A]^{2 \times 3} \cdot [B]^{3 \times 2} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{bmatrix} \cdot \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \\ b_{31} & b_{32} \end{bmatrix} = \begin{bmatrix} \sum_1^3 a_{1j} \cdot b_{j1} & \sum_1^3 a_{1j} \cdot b_{j2} \\ \sum_1^3 a_{2j} \cdot b_{j1} & \sum_1^3 a_{2j} \cdot b_{j2} \end{bmatrix}$$

Es decir, que cada elemento de la matriz resultante es el sumatorio de la fila y la columna de A y B correspondientes. Recuérdese que un sumatorio se define como:

$$\sum_{i=n}^m x_i = x_n + x_{n+1} + x_{n+2} + \dots + x_m$$

Ahora, con lo que sabemos, podemos representar un vector como una matriz de 1 x n dimensiones. Así pues, el producto escalar de un vector por otro, realmente se representa como:

$$\vec{u} \cdot \vec{v} = u^T \cdot v = \begin{bmatrix} u_x & u_y & u_z \end{bmatrix} \cdot \begin{bmatrix} v_x \\ v_y \\ v_z \end{bmatrix} = \sum_{i=1}^3 u_i \cdot v_i$$

Por último tenemos los tensores, que son elementos que generalizan los conceptos de escalares, vectores y matrices a dimensiones superiores. En un espacio vectorial, puede entenderse un tensor como un objeto multilineal que describe cómo cambian ciertas cantidades en relación a otras. Un ejemplo concreto es el tensor de tensiones, que representa los esfuerzos normales y tangenciales a los que está sometido cualquier punto de un cuerpo (aunque este tensor en concreto es bidimensional).

En general se puede decir que un tensor es una matriz de orden superior, esto es, que si un escalar está en un espacio de 1 dimensión, un vector en uno de n dimensiones, una matriz en uno de n x m dimensiones, un tensor, o matriz tridimensional, estará en uno de n x m x p dimensiones.


Como siempre la operación que más destaca en los tensores, como en los vectores y las matrices, es el producto. Aquí definiremos un nuevo tipo de producto, el producto tensorial o producto de kronecker, que da como resultado un tensor de orden mayor a las dimensiones de los factores. De forma generalizada, si tenemos dos matrices, A de orden m x n y B de orden p x q, el tensor resultante tendrá unas dimensiones de (m·p) x (n·q):

$$[A]^{m \times n} \otimes [B]^{p \times q} = \begin{bmatrix} a_{11} \cdot [B] & a_{12} \cdot [B] & \dots & a_{1n} \cdot [B] \\ a_{21} \cdot [B] & a_{22} \cdot [B] & \dots & a_{2n} \cdot [B] \\ \dots & \dots & \dots & \dots \\ a_{m1} \cdot [B] & a_{m2} \cdot [B] & \dots & a_{mn} \cdot [B] \end{bmatrix}$$

b. Cálculo

El cálculo, más concretamente, el cálculo infinitesimal, es la rama de las matemáticas que estudia los cambios y las variaciones en los sistemas. Se compone de dos ramas principales muy relacionadas., el cálculo diferencial, que estudia las derivadas, es decir, los cambios de las funciones, y el cálculo integral, que busca encontrar el acumulado de la función, es decir, su integral y, si existe, su función primitiva.

Pero, ¿qué es una función? Pues bien, una función es la relación entre dos magnitudes o conjuntos, conocidos como dominio y codominio, de forma que se asigna un valor al codominio por cada valor único del dominio.



De una forma más simple, una función es una especie de caja negra a la que metemos datos y nos saca resultados. La forma más común de denotar a las funciones es como $f(x)$, donde f es la función y x es el valor de entrada. Si nuestra función se define, por ejemplo, como:


$$f: \mathbb{R} \rightarrow \mathbb{R} \text{ donde } f(x) = x^2$$

En este caso x es el valor de entrada de la función y x^2 será el valor de salida de la misma, donde x y x^2 son números reales.

Por supuesto, la mayoría de las funciones pueden representarse gráficamente. Por ejemplo, la función:

$$f(x) = x^3 + x^2$$

donde los valores de la coordenada y son los valores de $f(x)$, quedando así un gráfico de la siguiente forma:



Por supuesto, las funciones no solamente tienen por qué tomar un solo dato ni tampoco tienen por qué devolver un valor escalar. Una función puede tener varias variables y devolver, por ejemplo, un vector, o tomar diferentes expresiones dependiendo de los valores del input.


$$f(x, y) = x^2 + 2y \text{ donde } f : \mathbb{R}^2 \rightarrow \mathbb{R}$$

$$\vec{g}(x) = \begin{bmatrix} 2x \\ x^2 \\ 3 \end{bmatrix} \text{ donde } g : \mathbb{R} \rightarrow \mathbb{R}^3$$

$$h(x, y) = \begin{cases} 0 & \text{si } x \leq 0 \text{ e } y \leq 0 \\ 2x^2 - 2y^2 & \text{si } x > 0 \text{ o } y > 0 \end{cases} \text{ donde } h : \mathbb{R}^2 \rightarrow \mathbb{R}$$

Conociendo ya el comportamiento de las funciones, podemos definir ahora lo que es una derivada. La derivación de las funciones responde a una pregunta muy simple, cuál es el valor de la pendiente en cada punto de una función.

Puesto que es muy difícil hallar el valor de la tangente a ojo sobre una gráfica, podemos intentar aproximarla de la siguiente forma: supongamos que tenemos una función cualquiera, continua que da un valor real en un punto x y que ahora cogemos otro punto de la función a una distancia h de x . Así pues podemos hacer una recta que une ambos puntos.



La recta que une $f(x)$ y $f(x+h)$ se irá aproximando más y más a la pendiente en el punto conforme más y más pequeña se vaya haciendo la h . De forma que la derivada de una función en un punto se define como:

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

Esto es, la derivada de una función en un punto es el límite cuando h tiende a ser 0 de la resta de los valores de la función en $x+h$ y x partido de la distancia, es decir, h .

Nótese que una función puede no ser derivable en un punto, por ejemplo, la derivada de la función $f(x) = 1/x$ no está definida cuando $x = 0$.

tipo de función	función	derivada
función constante	$f(x) = k$ donde $k \in \mathbb{R}$	$f'(x) = 0$
función identidad	$f(x) = x$	$f'(x) = 1$
función cuadrada	$f(x) = x^2$	$f'(x) = 2x$
función potencia general	$f(x) = x^n$	$f'(x) = n \cdot x^{n-1}$
función exponente en base e	$f(x) = e^x$	$f'(x) = e^x$
función exponente general	$f(x) = a^x$	$f'(x) = a^x \cdot \ln(a)$
función logaritmo neperiano	$f(x) = \ln(x)$	$f'(x) = 1/x$ donde $x > 0$
función logaritmo en base a	$f(x) = \log_a(x)$	$f'(x) = 1/(x \cdot \ln(a))$ donde $x > 0$

función seno	$f(x) = \text{sen}(x)$	$f'(x) = \cos(x)$
función coseno	$f(x) = \cos(x)$	$f'(x) = -\text{sen}(x)$
función tangente	$f(x) = \tan(x)$	$f'(x) = \sec^2(x) = 1/\cos^2(x) = 1 + \tan^2(x)$
función arcoseno	$f(x) = \arcsen(x)$	$f'(x) = 1/\sqrt{1-x^2}$
función arcocoseno	$f(x) = \arccos(x)$	$f'(x) = -1/\sqrt{1-x^2}$
función arcotangente	$f(x) = \arctan(x)$	$f'(x) = 1/(1+x^2)$
función seno hiperbólico	$f(x) = \sinh(x)$	$f'(x) = \cosh(x)$
función coseno hiperbólico	$f(x) = \cosh(x)$	$f'(x) = \sinh(x)$

Con estas funciones simples podemos componer prácticamente cualquier función más compleja y hallar su derivada siguiendo estas normas:

- Regla de la suma:
 $(f+g)' = f' + g'$
- Regla del producto:
 $(f \cdot g)' = f' \cdot g + f \cdot g'$
- Regla del cociente:
 $(f/g)' = (f' \cdot g - f \cdot g')/g^2$
- Regla de la cadena:
 $(g(f(x)))' = g'(f(x)) \cdot f'(x)$

La operación derivación se puede expresar a través del operador diferencial (D, d/dx, $\partial/\partial x$, ...)

$$\frac{\partial f(x)}{\partial x} = \frac{df(x)}{dx} = D_x \cdot f(x) = f'(x)$$

A su vez, una función que dependa de varias variables, puede derivarse por cada una de ellas, tratando al resto como constantes:

$$f(x, y) = 2xy + x - y^2$$

$$\frac{\partial f(x, y)}{\partial x} = 2y + 1$$

$$\frac{\partial f(x, y)}{\partial y} = 2x - 2y$$

Sabiendo esto, podemos definir el vector gradiente de un campo escalar como un campo vectorial cuyos elementos son las derivadas parciales del campo en cada punto e indica la dirección de máxima pendiente o cambio del campo.

$$\nabla \cdot f(x, y, z) = \begin{bmatrix} \frac{\partial}{\partial x} \\ \frac{\partial}{\partial y} \\ \frac{\partial}{\partial z} \end{bmatrix} \cdot f(x, y, z) = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \\ \frac{\partial f}{\partial z} \end{bmatrix}$$

Por otro lado, si tenemos un campo escalar, definiremos la matriz Jacobiana o, simplemente, el jacobiano, como la matriz de derivadas parciales de la función que define un campo vectorial.

Sea $f : \mathbb{R}^m \rightarrow \mathbb{R}^n$, su jacobiano será :

$$Jf(\vec{x}) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_m} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_m} \\ \cdots & \cdots & \cdots & \cdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \cdots & \frac{\partial f_n}{\partial x_m} \end{bmatrix} = \begin{bmatrix} \nabla f_1 \\ \nabla f_2 \\ \cdots \\ \nabla f_n \end{bmatrix}$$

Una función puede derivarse tantas veces como se quiera. Si se hace la derivada de la derivada de una función, se dice que estamos obteniendo una derivada de segundo orden.

$$\frac{\partial^2 f(x)}{\partial x^2} = \frac{\partial}{\partial x} \cdot \frac{\partial f(x)}{\partial x} = \frac{\partial f'(x)}{\partial x} = f''(x)$$

Es teorema de Clairaut demuestra que al hacer una derivación parcial múltiple cruzada, no importa el orden de la derivación:

$$\frac{\partial^2 f(x, y)}{\partial x \partial y} = \frac{\partial^2 f(x, y)}{\partial y \partial x}$$


Así pues, podemos definir el operador o matriz Hessiana de un campo o función escalar como:

$$H \cdot f(x_1, \dots, x_n) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \cdots & \cdots & \cdots & \cdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix} = \nabla \cdot \nabla^T \cdot f$$

Finalmente, el operador laplaciano puede aplicarse tanto a campos escalares como vectoriales.

$$\Delta f = \nabla \cdot \nabla \cdot f = \sum_{i=1}^n \frac{\partial^2 f}{\partial x_i^2}$$

Una integral es la operación que pretende calcular el área que queda entre el eje de ordenadas y la curva de la función.



Es importante diferenciar entre los conceptos de integral y primitiva. Una primitiva es la función que puede resultar de integrar, es decir, hallar el área de debajo de una función. Todas las funciones son integrables, pero no todas tienen primitiva.

Según el teorema fundamental del cálculo, las operaciones de derivación e integración son operaciones inversas.

Si la función $F(x) = \int_a^x f(t)dt$ es derivable $\implies F'(x) = f(x)$

Por lo que : $\int_a^b f(x)dx = F(b) - F(a)$

c. Estadística

La estadística es la disciplina que se encarga de recopilar, organizar e interpretar los datos así como de estudiar los procesos aleatorios por los que se generan.

Hay que diferenciar dos conceptos en estadística:

- La **posibilidad** es el conjunto cerrado de los valores que pueden tomar los datos. Por ejemplo, en un dado de 6 caras los valores posibles van de 1 a 6

- La **probabilidad** es una medida de la certidumbre con la que ocurrirá un evento aleatorio. Para el ejemplo anterior, los números en un dado deberán tener la misma probabilidad de salir.

Una vez recopilados los datos, se conoce como **población** al conjunto total de los mismos, mientras que una **muestra** será una parte de toda la población. Una **muestra representativa** es aquella cuyos resultados estadísticos se parecen a los del conjunto de la población.

La probabilidad es estudiada por la teoría de la probabilidad, que interpreta los modelos de procesos aleatorios o estocásticos (esto es, no deterministas).

Matemáticamente, definimos la probabilidad de que ocurra un suceso A como el total de veces que ha pasado dicho evento entre el total de las muestras obtenidas.

$$P(A) = \lim_{N \rightarrow \infty} \frac{n_A}{N}$$

Por ejemplo, la probabilidad de que salga cualquiera de los números en un dado es:

$$P(n) \simeq \frac{1}{6}$$

Algunas de las propiedades más representativas de una población estadística son:

- **Moda:** es el valor más representado
- **Media aritmética:** es el valor promedio de los datos obtenidos. Está muy relacionado con el concepto de esperanza en teoría de la probabilidad.

La media aritmética de una población se calcula como:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{x_1 + x_2 + \dots + x_n}{n}$$

Mientras que la esperanza se define como:

$$\mu = E[x] = \int_{\mathbb{R}} x \cdot f(x) dx$$

$$\mu = E[x] = \sum_{i=1}^n x \cdot P[X = x]$$

- **Varianza:** es una medida de la dispersión de los datos, es decir lo cerca o lejos que están del valor esperado o de la media.

$$\sigma^2 = \int_{\mathbb{R}} (x - \mu)^2 \cdot f(x) \cdot dx$$

$$\sigma^2 = \sum_{i=1}^n (x - \mu)^2 \cdot P(X = x) \cdot dx$$

- Dispersión típica:

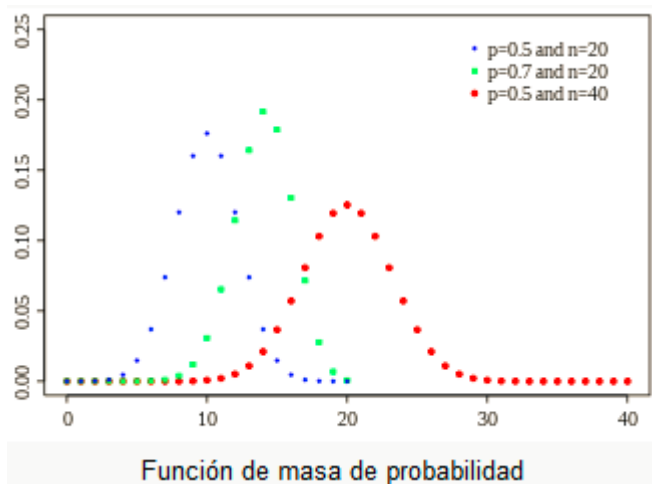
Una vez recopilados los datos, podemos agrupar los valores obtenidos. La función que describe cómo se organizan dichos datos es la que se conoce como distribución de probabilidad o función de densidad. Por ejemplo, para una serie de eventos con resultados discretos (como tirar muchos dados a la vez) puede utilizarse la distribución binomial:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k} = \frac{n!}{k!(n-k)!} \cdot p^k \cdot (1 - p)^{n-k}$$

Esta distribución te da la posibilidad de obtener k aciertos en una población de n cuando conoces la probabilidad p de éxito en un evento.

En el ejemplo anterior, si queremos conocer la probabilidad de obtener 30 veces un 3 en 50 tiradas de dados, tendríamos que:

$$P(X = 30) = \frac{50!}{30! \cdot 20!} \cdot \left(\frac{1}{6}\right)^{30} \left(\frac{5}{6}\right)^{20} \simeq 5.56 \cdot 10^{-12}$$



Si en lugar de obtener resultados discretos podemos obtener resultados reales, la distribución binomial se transforma en la **distribución normal** o **distribución de Gauss**. Esta distribución sigue una función de densidad de probabilidad así

$$\Phi_{\mu, \sigma}(X = x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot \exp\left(-\frac{(x - \mu)^2}{\sigma^2}\right)$$

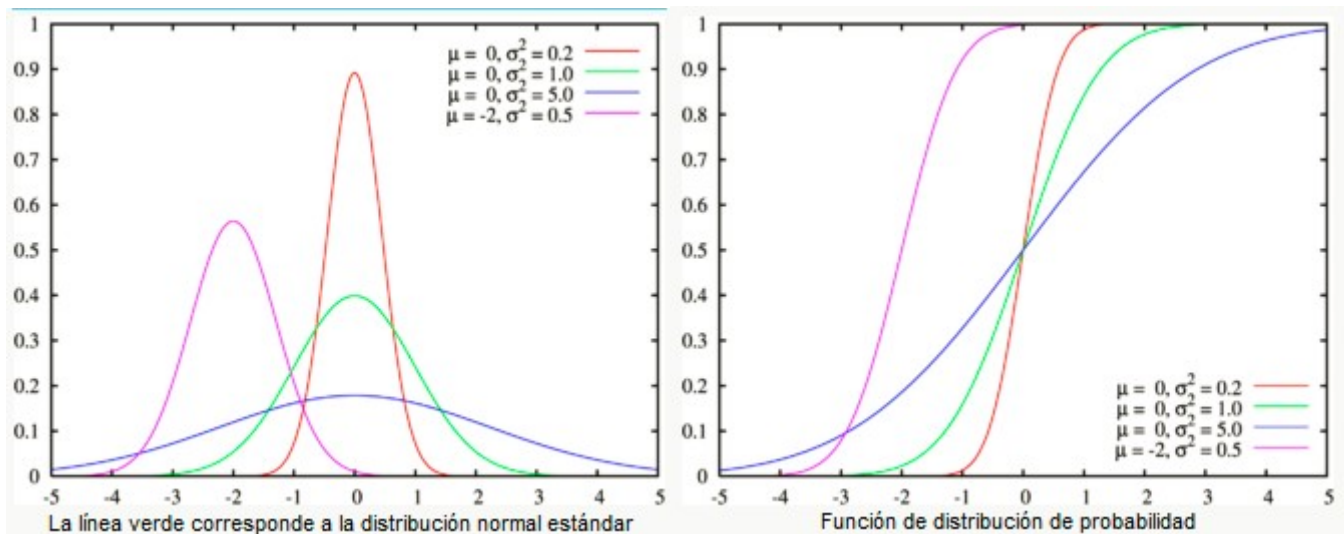
Dónde:

- Φ : es la función de densidad de probabilidad

- x : es el valor para el que queremos ver su probabilidad
- μ : es la media aritmética de la distribución
- σ : es la desviación normal
- σ^2 : es la varianza
- $\exp(f(x)) = e^{f(x)}$

Si queremos saber la probabilidad acumulada entre dos valores (a y b) haremos la integral de esta función entre a y b , pero cuidado, porque esta función no tiene primitiva

$$\Phi(a \leq X \leq b) = \frac{1}{\sigma\sqrt{2\pi}} \int_a^b \exp\left(-\frac{(u - \mu)^2}{2\sigma^2}\right) du$$



La distribución normal estándar es aquella con media 0 y desviación típica 1.

Otra distribución común es la distribución de Poisson, que es muy útil para representar probabilidades en el tiempo cuando los eventos son discretos (pueden tomar valores 0, 1, 2,...)

Se define como:

$$P(X = k) = \frac{e^{-\lambda} \cdot \lambda^k}{k!} \text{ donde } \lambda = \mu = \sigma^2$$

14. Bases de la Inteligencia Artificial

Se define grosso modo como **Inteligencia Artificial** (IA en español o AI en inglés, de "Artificial Intelligence") a un subcampo de las ciencias de la computación que pretende


emular la inteligencia de los sistemas biológicos y su toma de decisiones. Es un amplio campo de definición laxa y en muchos casos ligado al Minado de Datos para obtener modelos y predicciones.

La inteligencia artificial es un campo muy amplio que abarca muchos conceptos, de entre los cuales destacan:

- **Aprendizaje automático** o Machine Learning: se verá más adelante
- **Aprendizaje profundo** o Deep Learning: una subrama del anterior que se centra en el entrenamiento y aprendizaje de redes neuronales de gran tamaño y complejidad, capaces de aprender a reconocer patrones y encontrar soluciones fuera de aquellas para la que han sido entrenadas.
- **Redes neuronales** artificiales: se verá más adelante.
- **Visión por computadora**: una aplicación concreta de los conceptos anteriores que se encarga de clasificar, detectar objetos y procesar imágenes y vídeos.
- **Procesamiento del lenguaje natural** (NLP del inglés Natural Language Processing): se ocupa de la interacción de las máquinas y el lenguaje humano. Se encarga de procesar, clasificar y comprender textos, tanto escritos como hablados.
- Además, la IA tiene aplicaciones dentro de los campos de la robótica, con lo que se pretende crear robots con un mayor poder de decisión y resolución de problemas complejos, la minería de datos, para procesar de forma más eficiente grandes volúmenes de datos y poder hallar así patrones y relaciones entre los mismos.

Dentro de la inteligencia artificial se encuentra el campo del Aprendizaje Automático o Aprendizaje de Máquinas (más conocido por su terminología inglesa **Machine Learning**), que es la forma de hacer que un sistema de inteligencia artificial aprenda a hacer predicciones más o menos exactas.

Una de las formas más comunes de crear una IA es a través de los diferentes tipos de **máquinas neurales**, o redes neuronales o neurales (NN por sus siglas en inglés, "Neural Networks"). Una máquina neural son modelos computacionales que se basan en un modelo simplificado de las células nerviosas. En esta se tiene una serie de **neuronas** agrupadas en **capas** y unidas por **conexiones**. En general, las conexiones poseen una propiedad llamada **peso**, que indica lo fuerte que es esa conexión o, dicho de otro modo, lo importante que es esa conexión para la neurona en cuestión.



Una neurona obtendrá los pesos de todas sus conexiones de input y los sumará, dicha suma se llama **activación** y normalmente se le añade un término más denominado “**bias**”. Esta suma se pasará por una función, normalmente no lineal, denominada **función de activación**, que producirá el output que pasará a las neuronas de la siguiente capa.

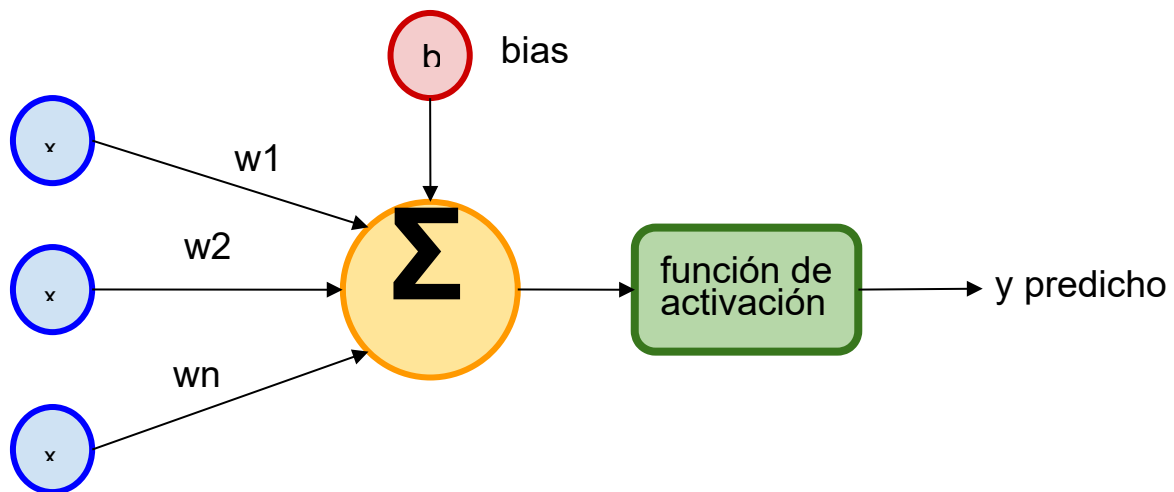
En una red neural la primera capa, o input, son los datos que queremos procesar, mientras que la última nos da los resultados de la predicción, por ejemplo, si en la imagen de input hay caras humanas, el output podría ser decirnos si en la imagen hay una cara o un conjunto de datos de la cara.

Una vez creado nuestro sistema de inteligencia artificial, es necesario entrenarlo para que sea capaz de hacer algo. Para esto existen varias estrategias, aunque las dos más populares son:

- **Aprendizaje supervisado:** se le da a la IA una serie de ejemplos resueltos y esta ajustará sus parámetros (pesos, bias, etc.) en función de la diferencia entre la solución predicha y la real que nosotros le hemos pasado.
- **Aprendizaje no supervisado:** en este caso se le pasan una serie de inputs sin decir la solución y la IA se entrena para encontrar patrones comunes en ellos.

a. Principios de las redes neuronales


Como ya se ha mencionado, una máquina neural se compone de neuronas y de conexiones entre ellas.



En este caso los outputs de las neuronas de la capa anterior (x_i) se multiplican por los pesos correspondientes (w_i), se suman entre ellos y con la bias (b), creando la activación. Finalmente, la activación se pasa por la función de activación para generar el output de nuestra neurona.

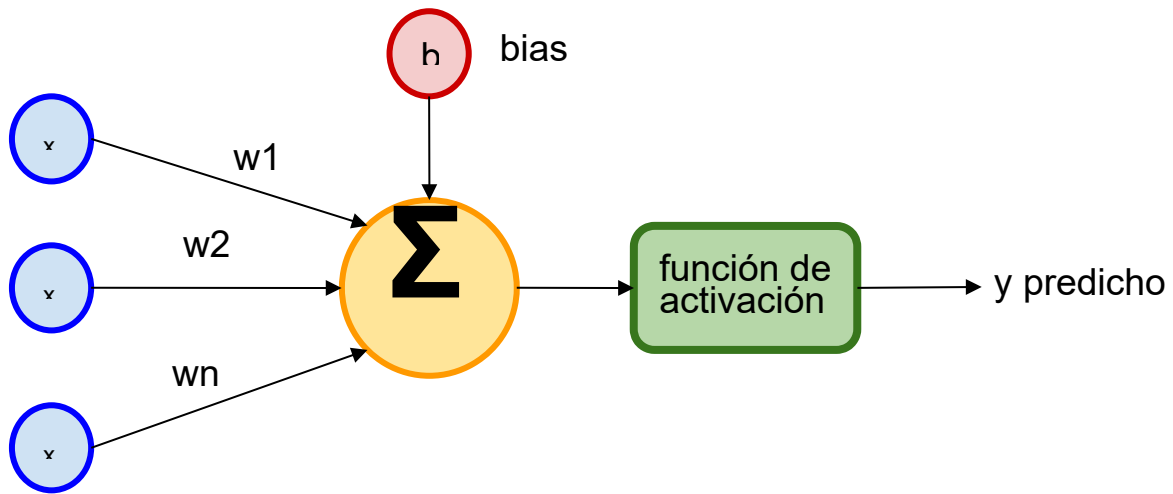
Para una red neuronal convencional, las neuronas se agrupan en capas, estando las capas de entrada y de salida, por donde pasan los datos y salen las predicciones, respectivamente, y las capas ocultas, que son todas aquellas que se encuentran entre las dos anteriores.

Una red neuronal convencional tendrá pues esta estructura:



b. Representación matricial de las redes neuronales

Cogiendo una red neuronal muy sencilla, lo que conocemos como perceptrón, para lo cual nos vale el ejemplo anterior:




Se puede ver aquí que el resultado, al que llamaremos “z”, que pasará por la función de activación puede expresarse de la siguiente manera:

$$z = x_1 \cdot w_1 + x_2 \cdot w_2 + x_3 \cdot w_3 + b$$

Mientras que el resultado final “y” será determinado por la salida de la función de activación $f(z)$:

$$y = f(z)$$

Pero qué pasará si ahora nosotros tenemos una capa de salida con varias neuronas, es decir, que los resultados pueden estar comprendidos en 3 valores (por ejemplo, si queremos detectar manzanas, peras y uvas, se asignará una neurona de salida a cada una de ellas, habiendo que interpretar después los resultados). Pues si ahora llamamos “a” a cada una de las funciones de activación, que por simplicidad meteremos en la propia neurona, y tenemos 4 entradas, quedaría una red de la siguiente forma:



entonces, esta red puede expresarse como un sistema de ecuaciones, de la forma:

$$\begin{cases} z_1 = w_{11} \cdot x_1 + w_{12} \cdot x_2 + w_{13} \cdot x_3 + w_{14} \cdot x_4 + b_1 & \rightarrow y_1 = a_1(z_1) \\ z_2 = w_{21} \cdot x_1 + w_{22} \cdot x_2 + w_{23} \cdot x_3 + w_{24} \cdot x_4 + b_2 & \rightarrow y_2 = a_2(z_2) \\ z_3 = w_{31} \cdot x_1 + w_{32} \cdot x_2 + w_{33} \cdot x_3 + w_{34} \cdot x_4 + b_3 & \rightarrow y_3 = a_3(z_3) \end{cases}$$

Este sistema de ecuaciones lineales se puede expresar como una multiplicación de matrices:

$$\begin{bmatrix} w_{11} & w_{12} & w_{13} & w_{14} \\ w_{21} & w_{22} & w_{23} & w_{24} \\ w_{31} & w_{32} & w_{33} & w_{34} \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} + \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix} = \begin{bmatrix} z_1 \\ z_2 \\ z_3 \end{bmatrix}$$


En aras de la simplificación, la matriz de pesos se llamará W , el conjunto de inputs será x , los términos independientes o bias el vector b y la entrada a la función de activación la z .

$$W_{3 \times 4} \cdot x_{4 \times 1} + b_{3 \times 1} = z_{3 \times 1}$$

Pero esto sería solamente para un input, normalmente se meterá un conjunto de inputs, uno detrás de otro, para obtener varios resultados, lo que se conoce como **batch**. Entonces, las dimensiones de las salidas cambiarán:

$$W_{3 \times 4} \cdot x_{4 \times n} + b_{3 \times n} = z_{3 \times n}$$

Pero esto solamente sería útil para una red neuronal en la que solamente hubiera una capa de entrada y otra de salida. Lo normal es que una red neuronal contenga capas intermedias, conocidas como capas ocultas. Pongamos ahora la siguiente red:



Ahora el proceso anterior deberá repetirse capa a capa.

- 1) Calculamos el valor de la salida de la capa oculta 1:

$$\vec{z}_1 = [W_1] \cdot \vec{x} + \vec{b}_1$$

- 2) Pasamos el anterior valor por su función de activación

$$\vec{a}_1 = f_1(\vec{z}_1)$$

- 3) El resultado anterior lo pasamos por la capa de salida

$$\vec{z}_2 = [W_2] \cdot \vec{a}_1 + \vec{b}_2$$

- 4) Se pasa todo por la función de activación de la salida para obtener los valores finales

$$\vec{y} = f_2(\vec{z}_2)$$

Este proceso es lo que se conoce como forward propagation o propagación hacia delante.

Las funciones de activación de las neuronas son útiles puesto que pueden añadir una componente no lineal a un sistema intrínsecamente lineal, esto permite detectar patrones más complejos que un sistema lineal no permitiría.

Pero, ¿por qué es problemático que una red neuronal tenga solamente componentes lineales? Pues bien, supongamos que tenemos una red neuronal con una capa de salida, 2 capas ocultas intermedias y 1 capa de entrada y que en ninguna hay funciones de activación.

Al no haber funciones de activación, la salida de las neuronas es, directamente, el resultado de la operación lineal:

$$z_i = w_{i1} \cdot x_1 + w_{i2} \cdot x_2 + \dots + w_{in} \cdot x_n + b_i$$

Si extendemos esto al resto de neuronas de la capa, nos dará un sistema de ecuaciones lineales de la forma:

$$\vec{z}_1 = [W_1] \cdot \vec{x} + \vec{b}_1$$

Esta será la entrada a la siguiente capa oculta, cuya salida, al no tener tampoco función de activación, será:

$$\begin{aligned} \vec{z}_2 &= [W_2] \vec{z}_1 + \vec{b}_2 = [W_2] \cdot ([W_1] \vec{x} + \vec{b}_1) + \vec{b}_2 = \\ &= [W_2] \cdot [W_1] \cdot \vec{x} + ([W_2] \cdot \vec{b}_1 + \vec{b}_2) \end{aligned}$$

Podemos simplificar ahora las dos matrices de pesos como una matriz y unir los vectores de la bias en un solo elemento:

$$\vec{z}_2 = [W_{12}] \cdot \vec{x} + \vec{b}_{12}$$

Aplicando esta misma lógica a la capa de salida, tenemos que:

$$\begin{aligned} \vec{y} &= [W_3] \cdot \vec{z}_2 + \vec{b}_3 = [W_3] ([W_{12}] \cdot \vec{x} + \vec{b}_{12}) + \vec{b}_3 \\ \vec{y} &= [W_{123}] \cdot \vec{x} + \vec{b}_{123} \end{aligned}$$

Entonces, la salida es una combinación lineal del vector de entrada. Esto significa que en nuestra red neural no importa las capas que hayamos metido ni el número de neuronas de las mismas, nuestro modelo no será más complejo que uno con una capa de entrada y una capa de salida. De ahí la importancia de las funciones de activación, pues añaden esa componente no lineal que permite a los sistemas de redes neuronales detectar patrones más complejos.

Aunque no todas las funciones de activación lo tienen por qué cumplir, hay tres recomendaciones principales:

- La función debe ser, preferentemente, no lineal por los motivos mencionados previamente.
- El rango de la función nos permite decidir entre la rapidez y la estabilidad del entrenamiento. Un rango finito permite que métodos de aprendizaje basados en el gradiente sean más estables, mientras que un rango de activación infinito da un entrenamiento más eficiente.

- Una función que es continuamente diferenciable, es decir, que tiene derivada en todo su rango, permite utilizar también métodos basados en el gradiente.

Existen muchas funciones de activación ampliamente utilizadas, pero algunas de las más comunes son:

La **función identidad**: esta función no añade la condición de no linealidad, pero a veces se usa para representar que la salida de la capa inicial es la misma que el tensor de entrada.

$$f(x) = x$$

La **función ReLu** (Rectified Linear): la salida de la función es una recta si la entrada es mayor que 0 y la salida es 0 si la entrada es menor que 0. Esta función ha ganado gran popularidad a raíz de su uso en deep learning

$$f(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ x & \text{si } x > 0 \end{cases}$$

La **función Logística** o **sigmoide**: permite mapear cualquier valor de entrada entre 0 y 1, sufriendo además el mayor cambio en los valores cercanos a 0, permitiendo así una clasificación binaria de la entrada y el desprecio de valores de entrada muy bajos o muy altos.

$$f(x) = \frac{1}{1 + e^{-x}} \text{ donde } f(x) \in (0, 1)$$

Relacionado con lo anterior, la **función tangente hiperbólica** permite mapear de manera similar los resultados en un rango de (-1, 1):

$$f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \text{ donde } f(x) \in (-1, 1)$$

Al igual que la función sigmoide y la tangente hiperbólica son similares, hay funciones similares a la función ReLu que ayudan con sus limitaciones.

Las funciones **Leaky ReLu** y **PReLU** (Parametric Rectified Linear) añaden una recta de menor pendiente en el caso de inputs negativos.

$$f(x) = \begin{cases} 0.01 \cdot x & \text{si } x \leq 0 \\ x & \text{si } x > 0 \end{cases}$$

$$f(x) = \begin{cases} \alpha x & \text{si } x \leq 0 \\ x & \text{si } x > 0 \end{cases}$$

Sin embargo, para casos en los que la función deba ser derivable en todo su rango, podemos utilizar funciones como la SiLu (sigmoid linear), la ELU (exponential linear) o la GeLu (gaussian error linear)

$$f(x) = \frac{x}{1 + e^{-x}}$$

$$f(x) = \begin{cases} \alpha(e^x - 1) & \text{si } x \leq 0 \\ x & \text{si } x > 0 \end{cases}$$

$$f(x) = x \cdot \Phi(x)$$

Otras funciones también utilizadas son:

- función gaussiana
- Softplus
- Softmax

c. Entrenamiento e hiperparámetros

Una vez definida la estructura de nuestra red neuronal, debemos definir un algoritmo que se encargue de entrenarla. Este algoritmo estará controlado por unos parámetros que controlarán todos los aspectos del aprendizaje. A diferencia de otros parámetros, como los pesos, los hiperparámetros afectan por igual a toda la estructura de la red.

Uno de los parámetros más comunes es el ratio de aprendizaje, o “**learning-rate**”, que indica lo rápido o lento que nuestras neuronas cambian sus parámetros con cada entrenamiento. Resulta antiintuitivo que un learning-rate muy alto pueda evitar que una NN se entrene adecuadamente, pues podría pasar que el cambio tan repentino de los parámetros de la red evite que esta produzca un modelo satisfactorio. Por otro lado, una red con un learning-rate muy bajo sería incapaz de aprender adecuadamente antes de terminar el entrenamiento.

En cada etapa del entrenamiento será necesario calcular el error entre el resultado predicho y el valor actual (en un entrenamiento supervisado), para poder hacer las correcciones necesarias. Este error se conoce como pérdida o “**loss**” y viene calculado por su “**loss function**”.

Una vez calculado el error, antes de la nueva etapa de entrenamiento, se calculan los nuevos pesos de las conexiones por un método conocido como “**backpropagation**”, o propagación hacia atrás, que permite obtener todos estos pesos rápidamente.

La pérdida se puede calcular de muchas formas, aunque una de las más sencillas y ampliamente utilizada es a través del error cuadrático medio:

$$ECM = \frac{1}{n} \sum_{i=1}^n (y_{real} - y_{pred})_i^2$$


Donde y_{real} es lo que debería valer la salida para ese objeto e y_{pred} es lo que ha predicho la red neuronal que vale.

Una vez definida nuestra función de pérdida podemos decidir qué método de entrenamiento usar para minimizarla. Un ejemplo sencillo sería por ejemplo, una red neuronal con una función de pérdida tipo EMC y un modo de entrenamiento de descenso por gradiente.

$$L(\vec{y}) = EMC = \frac{1}{n} \sum_{i=1}^n (y_{real} - y_{pred})_i^2$$

Si L (la pérdida) es una función de la salida, la cual depende de todos los parámetros de la red, podemos definir el gradiente de L con respecto a esos parámetros utilizando la lógica de la backpropagation.

Por ejemplo, supongamos la siguiente red:



Entonces, la derivada de L con respecto a, por ejemplo, el peso w_1 será:

$$\frac{\partial L(w_1)}{\partial w_1} = \frac{\partial L}{\partial y_{pred}} \frac{\partial y_{pred}(w_1)}{\partial w_1} = \frac{\partial L}{\partial y_{pred}} \frac{\partial y_{pred}}{\partial h_1} \frac{\partial h_1}{\partial w_1}$$

$$\frac{\partial L(w_1)}{\partial w_1} = \frac{\partial L}{\partial y_{pred}} \frac{\partial y_{pred}}{\partial h_1} \frac{\partial h_1}{\partial z_1} \frac{\partial z_1}{\partial w_1}$$

Vamos a calcular cada una de estas derivadas. Pero por simplicidad, vamos a decir que solamente hay un resultado, es decir, una y_{pred} .

La derivada de la pérdida con respecto al resultado obtenido será:

$$\frac{\partial L}{\partial y_{pred}} = \frac{\partial (y_{real} - y_{pred})^2}{\partial y_{pred}} = -2(y_{real} - y_{pred})$$

Aplicando la propagación hacia atrás para el resto de funciones:

Además z_1 , z_2 , y z_3 son las partes lineales de las neuronas, que tienen la forma:

$$z_{neurona} = \sum_{i=1}^n w_i \cdot x_i + b_{neurona}$$

$$y_{pred} = f_{act}(z_3) = \frac{1}{1 + e^{-z_3}}$$

$$\frac{\partial y_{pred}}{\partial z_3} = \frac{e^{-z_3}}{(1 + e^{-z_3})^2}$$

$$z_2(h_1) = h_1 \cdot w_5 + h_2 \cdot w_6 + b_3$$

$$\frac{\partial z_2}{\partial h_1} = w_5$$

$$h_1 = f_{act}(z_1) = \frac{1}{1 + e^{-z_1}}$$

$$\frac{\partial h_1}{\partial z_1} = \frac{e^{-z_1}}{(1 + e^{-z_1})^2}$$

$$z_1(w_1) = x_1 \cdot w_1 + x_2 \cdot w_2 + b_1$$



$$\frac{\partial z_1}{\partial w_1} = w_1$$

Podríamos hallar la fórmula que relaciona la salida con w_1 , pero en la realidad simplemente iremos hallando los valores capa a capa y paso a paso hacia atrás.

Aparte de la backpropagation, existen varios métodos que permiten ajustar el entrenamiento de la red neuronal. Algunos de los más comunes son:



- **Descenso por gradiente (Gradient Descent)**: en cada iteración del entrenamiento se busca la forma de cambiar los pesos de forma que la pérdida haya bajado lo máximo en la siguiente fase.

Podemos imaginar que empezamos a entrenar en lo alto de una colina y que nuestra solución óptima se encuentra en un valle al pie de la misma, la forma más eficiente de descender dicha colina es siguiendo el vector que nos da su gradiente.



- **descenso por gradiente con momento:** en este método se le añade un momento al descenso por gradiente, que viene dado por el acumulado de los gradientes anteriores.

Si siguiendo el ejemplo anterior, pudiera pasar que si solamente siguiéramos el gradiente, nos encontraríamos con un mínimo local a mitad de la altura de la colina. Sin embargo, si hemos descendido la colina corriendo, teniendo en cuenta nuestra propia inercia, podremos sortear dicho obstáculo y encontrar así una nueva zona de descenso.



- **Regularización:** es un conjunto de métodos que impiden que los pesos se hagan muy grandes y así ocurra un overfitting, para ello, se utilizan técnicas como la regresión.
- **Dropout:** consiste en desactivar aleatoriamente ciertos pesos y neuronas, evitando así una sobredependencia entre ellas y forzando a encontrar nuevos patrones.

- Aprendizaje por lotes (**Batch learning**): ayuda en la eficiencia computacional del entrenamiento al corregir los pesos después de pasar cada lote (batch) y no después de terminar una época del entrenamiento.

También hay hiperparámetros que afectan directamente a los sets de entrenamiento, como, por ejemplo, la proporción entre las partes de test y train del dataset, el tamaño del batch, el número de épocas que deberá durar el entrenamiento, etc.

En general, el objetivo de un entrenamiento es el de disminuir al mínimo el error a la vez que se maximiza la capacidad de predicción de la red.

A la hora de entrenar, nosotros dividiremos nuestro dataset en varias partes: train, valid y test. La parte de train se encarga de entrenar la red y cambiar los pesos, la parte de valid de cambiar los hiperparámetros necesarios para la siguiente época de entrenamiento y la parte de test comprueba los resultados de cada época. A la hora de realizar el dataset debemos hacerlo de forma que quede una parte representativa de cada tipo de input en todas las partes, si no, el entrenamiento no podrá ser tan bueno como deseamos.

Una vez creado nuestro dataset de entrenamiento, comenzaremos con el entrenamiento en sí. Un entrenamiento supervisado consiste en pasar reiteradamente el dataset separado en conjuntos de inputs (el tamaño de este conjunto se conoce como **batch-size**), para finalmente hacer las correcciones correspondientes debido al error calculado entre la predicción y la realidad. Cada etapa del entrenamiento se denomina **época**.


En cualquier caso, hay que tener en cuenta que una red neuronal producirá predicciones que nunca serán acertadas al 100%. Mediante el manejo de los hiperparámetros podemos obtener modelos que obtengan unas muy buenas predicciones, pero es normal toparse con dos problemas al diseñar dicho entrenamiento:

- **Undertraining**: los resultados pueden mejorarse porque el entrenamiento no ha sido lo suficientemente largo para los hiperparámetros dados.
- **Overtraining**: este puede resultar menos intuitivo. Si se deja un modelo entrenar durante demasiado tiempo, adecuará la red casi a la perfección para el dataset de entrenamiento (habrá bajado su loss al mínimo posible), sin embargo, será incapaz de realizar predicciones de cualquier cosa fuera del dataset de entrenamiento.

También podemos encontrar problemas a la hora de entrenar pero debido a la estructura de nuestra red:

- **Underfitting**: nuestra red es demasiado simple para los inputs
- **Overfitting**: nuestra red es demasiado compleja y no puede ser entrenada satisfactoriamente para la cantidad de inputs que tenemos.

d. Tipos de redes neuronales



[the mostly complete chart of neural networks](#)

e. Machine Learning in Python

Aun no conociendo paquetes y módulos diseñados expresamente para inteligencia artificial, podemos empezar a programar en python una red neuronal, con fines meramente educativos.


Podemos crear una primera neurona como un objeto de una clase propia neurona, a la cual creamos con sus pesos, su bias y su función de activación:

```
import numpy as np

def sigmoid(x):
    return 1/(1+np.exp(x))

class neuron():
    def __init__(self, weights, bias, act_func):
        self.weights = weights # pesos conectados a la neurona
        self.bias = bias
        self.act_func = act_func # funcion de activacion
    def feed_forward(self, inputs):
        # Operacion lineal
        z = np.dot(self.weights, inputs) + self.bias
        # lo pasamos por la función de activación
        return self.act_func(z)
```

Así pues, si tenemos la siguiente máquina neural:



Podemos definir otra clase para nuestra máquina neural utilizando la clase anterior.

```
class my_neural_network():
    def __init__(self):
        # Creamos los pesos de forma aleatoria
        # Los guardamos en una matriz,
        # cada fila serán los pesos de una neurona
        random_weights = np.random.rand(3,2)

        # ponemos las bias a 0, por ejemplo
        bias = 0

        # generamos las neuronas
```

```

self.h1 = neuron(random_weights[0], bias, sigmoid)
self.h2 = neuron(random_weights[1], bias, sigmoid)
self.out = neuron(random_weights[2], bias, sigmoid)

def feed_forward(self, inputs):
    # Salidas de las neuronas
    out_h1 = self.h1.feed_forward(inputs)
    out_h2 = self.h2.feed_forward(inputs)

    # entrada a la neurona de salida
    in_out = np.array([out_h1, out_h2])

    # devolvemos la salida de la ultima neurona
    return self.h1.feed_forward(in_out)

```

Por supuesto, lo siguiente será generar el dataset. En nuestro caso queremos ver si es posible inferir el género de una persona a través de su peso y altura. Para simplificar el ejemplo diremos que sí, que los hombres en general pesan más y son más altos.

Los primeros datos que creemos podemos limpiarlos, dejando, en lugar del peso total de cada persona, su desviación al peso medio de la población, y haremos lo mismo con la altura. Esto es importante, pues, al trabajar con una función sigmoide, si trabajamos con números muy altos su resultado será siempre 0.

$$\text{Si } x \gg 0 \quad f(x) = \frac{1}{1 + e^{-x}} \simeq 1 \implies f'(x) = f(x)(1 - f(x)) \simeq 0$$

Vamos a definir nuestra función de pérdida como una pérdida MSE:

```

def mse_loss(y_real_lst, y_pred_lst):
    mse_lst = []
    for y_real, y_pred in zip(y_real_lst, y_pred_lst):
        mse_lst.append((y_real - y_pred) ** 2)
    return mean(mse_lst)

```

Lo último que nos queda por definir es el algoritmos de entrenamiento. Recordamos que en cada etapa entrenamiento se pasa el dataset entero y, con los datos obtenidos se actualizan los pesos siguiendo una propagación hacia atrás.

Crearemos el entrenamiento como un método de la clase de la red neuronal.

f. Keras y TensorFlow

Keras y TensorFlow son dos módulos de Machine Learning para Python muy relacionados y ampliamente usados y que suelen usarse a la vez debido a su estabilidad y eficiencia para desarrollar Inteligencias Artificiales.

Puesto que Keras ahora está incluida en TensorFlow, podemos instalar ambos módulos a la vez con una instancia de pip

```
pip install --user tensorflow
```

para mostrar que la instalación ha sido correcta, podemos hacer un pip show:

```
pip show tensorflow
pip show keras
```

Una vez instalado el paquete, podemos empezar a probarlo. Para empezar, intentaremos traer uno de los datasets preconstruidos (por ejemplo el dataset de números escritos a mano, el MNIST).

```
import tensorflow as tf

mnist = tf.keras.datasets.mnist

# lo separamos en train y test
(x_train, y_train), (x_test, y_test) = mnist.load_data()

# normalizamos los valores
x_train, x_test = x_train / 255.0, x_test / 255.0
```

En este dataset, los valores se encuentran comprendidos entre 0 y 255 (negro y blanco, respectivamente), lo normalizamos al rango de 0 a 1 para ayudar en las operaciones.

Construyamos ahora nuestro primer modelo, es decir, nuestra máquina neural:

```
model = tf.keras.models.Sequential([
    tf.keras.layers.Flatten(input_shape=(28, 28)),
    tf.keras.layers.Dense(128, activation='relu'),
    tf.keras.layers.Dropout(0.2),
    tf.keras.layers.Dense(10)
])
```

En keras, un modelo es una clase que puede ser entrenada pero que también puede inferir datos, esto es, predecir.

Este modelo tiene varias capas de neuronas:

- **tf.keras.layers.Flatten(input_shape=(28, 28))**: convierte la imagen de una matriz de 28x28 píxeles en un array continuo de 784 elementos
- **tf.keras.layers.Dense(128, activation='relu')**: una capa densamente unida a la anterior con 128 neuronas y una función de activación ReLu.
- **tf.keras.layers.Dropout(0.2)**: esta capa solamente será útil durante el entrenamiento, lo que hace es desconectar un 20% de los pesos entre la capa oculta anterior y la capa de salida para mejorar los resultados y evitar un overfitting.

- **tf.keras.layers.Dense(10)**: una capa de salida con 10 salidas (los números de 0 a 9)

Podemos ahora llamar a nuestro modelo y hacer predicciones con nuestro dataset de testeo.

```
predictions = model(x_train[:1]).numpy()
print(predictions)
```

Pero sucede ahora una cosa, queremos los valores de salida como probabilidades de que sea uno de los 10 dígitos, sin embargo, la salida del modelo nos devuelve un tensor compuesto por logits.

```
[[-0.6166219 -0.2707992 -0.02922171 -0.7376434 -0.34330767
 0.22071683  0.27627766 -0.17214718  0.37605685  0.0405116 ]]
```

Los logits son una unidad de salida en crudo. Si pasamos esos elementos por una función de normalización (que deje los valores entre 0 y 1) podremos convertirlos en un número que indique lo seguro que está el modelo de que sea cada uno de los números.

```
predictions = tf.nn.softmax(predictions).numpy()
print(predictions)
```

Ahora los valores de salida serán:

```
[[0.05762834 0.0814376  0.10369093 0.05105957 0.07574169 0.1331336
 0.14073998 0.08988123 0.15550739 0.11117972]]
```

Sin embargo, todavía no hemos entrenado el modelo. Para ello, antes hay que hacer 2 cosas:

- Definir una función de pérdida:
- Compilar el modelo, dándole un optimizador y diciéndole qué métrica queremos emplear para ser evaluada.

```
# función de pérdida
loss_fn =
tf.keras.losses.SparseCategoricalCrossentropy(from_logits=True)

#compilamos el modelo
model.compile(optimizer='adam',
              loss=loss_fn,
              metrics=['accuracy'])
```

Ahora, para entrenar el modelo, simplemente tenemos que hacer:

```
model.fit(x_train, y_train, epochs=5)
```

Finalmente, para evaluar los resultados, podemos pasarle el dataset de testeo:

```
model.evaluate(x_test, y_test, verbose=2)
```

Finalmente, podemos envolver un modelo en otro. Por ejemplo, supongamos que queremos saber las probabilidades de que sea cada número el detectado. Pues definiremos un modelo nuevo que contiene a nuestro modelo, cuya salida se pasa por una capa softmax

```
probability_model = tf.keras.Sequential([
    model,
    tf.keras.layers.Softmax()
])
```

si ahora hacemos la siguiente prueba:

```
pred_2 = model(x_test[0])
pred_2_prob = probability_model(x_test[0])

print(pred_2)
print(tf.nn.softmax(pred_2).numpy())
print(pred_2_prob)
```

Nos salen los siguientes resultados:

- En logits:
[-4.997998 -8.502667 -0.8120431 1.8174555 -14.690332 -
4.3455963 -17.837069 11.50545 -3.2679763 -3.1090052]
- pasado por una softmax:
[6.8016469e-08 2.0443518e-09 4.4725093e-06 6.2019455e-05
4.2003666e-12 1.3060165e-07 1.8058310e-13 9.9993253e-01
3.8366596e-07 4.4977304e-07]
- Lo mismo que lo anterior pero habiendo definido un modelo que contiene la softmax:
[6.8016469e-08 2.0443518e-09 4.4725093e-06 6.2019455e-05
4.2003666e-12 1.3060165e-07 1.8058310e-13 9.9993253e-01
3.8366596e-07 4.4977304e-07]

Podemos encontrar varios tutoriales más en la página oficial de tensorflow:

<https://www.tensorflow.org/tutorials>

g. Redes Neurales Convolucionales

15. Google Colab, Yolo, Roboflow y Labelling

Yolo ("You Only Look Once") es un modelo de detección de objetos que divide las imágenes en una cuadrícula, haciendo una detección de objetos común sobre cada parte de esta.

Existen diferentes versiones del modelo Yolo, nosotros trabajaremos con YOLOv5. Para instalarlo en nuestro proyecto de Colab, haremos:

```
git clone https://github.com/ultralytics/yolov5.git
```

Después deberemos ir al directorio de YOLOv5 y allí instalar el archivo de requerimientos:

```
cd yolov5  
pip install -r requirements.txt
```

Una vez hecho esto podemos instalar nuestro dataset de imágenes y labels: